Programa de Pós-Graduação em Computação – PPGC

Aplicação de inteligência artificial para previsão de enchentes e mitigação de impactos nas comunidades costeiras

Daiane Wan-Dall Splitter da Silva

Dissertação de Mestrado do Programa de Pós-Graduação em Computação (PPGC)

Mestrado em Computação Aplicada - MCA

UNIVALI

PPGCA - Univali

Data de Depósito:

Assinatura: _____

Daiane Wan-Dall Splitter da Silva

Aplicação de inteligência artificial para previsão de enchentes e mitigação de impactos nas comunidades costeiras

Dissertação apresentada ao Programa de Pós-Graduação em Computação – PPGC, como parte dos requisitos para obtenção do título de Mestra em Computação Aplicada. *EXEMPLAR DE DEFESA*

Linha de Pesquisa: Sistemas Inteligentes e Educacionais

Orientador: Prof. Dr. Rodrigo Sant'Ana

Univali – CAMPUS Itajaí
Outubro de 2026

Daiane Wan-Dall Splitter da Silva

Application of artificial intelligence for flood prediction and impact mitigation in coastal communities

Master dissertation submitted to the Postgraduate Program in Computing – PPGC, in partial fulfillment of the requirements for the degree of the Master Program in Applied Computing. *EXAMINATION BOARD PRESENTATION COPY*

Research line: Intelligent and Educational Systems

Advisor: Prof. Dr. Rodrigo Sant'Ana

Univali – CAMPUS Itajaí
October 2026

RESUMO

SILVA, D. W. S. **Aplicação de inteligência artificial para previsão de enchentes e mitigação de impactos nas comunidades costeiras**. 2026. 42 p. Dissertação (Mestrado em Computação Aplicada) – Programa de Pós-Graduação em Computação, Universidade do Vale do Itajaí, Itajai – SC, 2026.

Este projeto tem como objetivo o desenvolvimento de um modelo preditivo para a previsão de enchentes em comunidades costeiras do estado de Santa Catarina, utilizando técnicas avançadas de inteligência artificial. O aumento da frequência e da intensidade de eventos climáticos extremos, como chuvas intensas, marés elevadas e alagamentos, tem afetado diretamente a vida das populações litorâneas, ocasionando prejuízos sociais, ambientais e econômicos consideráveis. Nesse contexto, torna-se essencial a antecipação desses eventos, por meio de métodos mais precisos e eficazes do que os atualmente utilizados. A proposta deste trabalho é criar um sistema preditivo baseado na análise de dados ambientais, climáticos, hidrológicos e socioeconômicos, com foco na identificação de padrões e na projeção de cenários futuros de risco. Justifica-se a relevância da pesquisa pela possibilidade de oferecer uma ferramenta capaz de auxiliar a tomada de decisão por parte de autoridades e órgãos de proteção civil, promovendo maior segurança, planejamento urbano eficiente e proteção de áreas vulneráveis. A metodologia a ser adotada é de natureza aplicada, com abordagem quantitativa e método hipotético-dedutivo. O projeto incluirá a consolidação de um banco de dados estruturado com informações provenientes de sensores ambientais, imagens de satélite e registros históricos de enchentes. Serão aplicadas técnicas de aprendizado de máquina para o desenvolvimento, ajuste e validação dos modelos preditivos. Espera-se, como resultado, a criação de um modelo robusto e confiável, capaz de antecipar a ocorrência de enchentes com maior precisão, identificar áreas de risco com base em múltiplas variáveis e contribuir para a formulação de políticas públicas voltadas à mitigação de desastres naturais em ambientes costeiros. O trabalho visa gerar impacto social positivo e ampliar o uso da inteligência computacional na gestão de riscos ambientais.

Palavras-chave: Inteligência Artificial. Previsão de Enchentes. Comunidades Costeiras..

ABSTRACT

SILVA, D. W. S. **Application of artificial intelligence for flood prediction and impact mitigation in coastal communities**. 2026. 42 p. Dissertação (Mestrado em Computação Aplicada) – Programa de Pós-Graduação em Computação, Universidade do Vale do Itajaí, Itajai – SC, 2026.

This project aims to develop a predictive model for flood forecasting in coastal communities of the state of Santa Catarina, Brazil, using advanced artificial intelligence techniques. The increasing frequency and intensity of extreme weather events, such as heavy rainfall, high tides and flooding, has directly affected the lives of coastal populations, causing considerable social, environmental and economic losses. In this context, anticipating these events through methods that are more accurate and effective than those currently in use becomes essential. The proposal of this work is to create a predictive system based on the analysis of environmental, climatic, hydrological and socioeconomic data, focusing on the identification of patterns and on the projection of future risk scenarios. The relevance of the research is justified by the possibility of offering a tool able to support decision-making by authorities and civil protection agencies, promoting greater safety, efficient urban planning and protection of vulnerable areas. The methodology to be adopted is applied in nature, with a quantitative approach and the hypothetico-deductive method. The project will include the consolidation of a structured database with information from environmental sensors, satellite images and historical flood records. Machine learning techniques will be applied for the development, tuning and validation of the predictive models. The expected result is a robust and reliable model able to anticipate the occurrence of floods with greater accuracy, identify risk areas based on multiple variables and contribute to the formulation of public policies aimed at mitigating natural disasters in coastal environments. The work aims to generate positive social impact and to expand the use of computational intelligence in environmental risk management.

Keywords: Artificial Intelligence. Flood Forecasting. Coastal Communities..

LISTA DE FIGURAS

Figura 1 – Fluxo de identificação, deduplicação, triagem automatizada e estratificação do corpus, no formato de relato do PRISMA. A triagem foi automatizada, sem avaliação manual por revisores. O total de 16.845 soma as exportações (inclui duas exportações sobrepostas da Scopus). Todos os valores foram reproduzidos pela reexecução do código sobre os arquivos brutos; entre os 16.845 e os 11.547 estão 539 registros sem DOI descartados. 24
Figura 2 – Dinâmica temporal do corpus selecionado. Em (a), 2026 representa um ano parcial. Em (b), as citações são apresentadas em escala bruta e refletem a data de extração, a cobertura das bases e o tempo de acumulação. 28
Figura 3 – Perfil tecnológico do corpus. As contagens são frequências de ocorrência em metadados harmonizados e não representam conjuntos mutuamente exclusivos de artigos. 29
Figura 4 – Países com maior número de publicações segundo os metadados de afiliação. A unidade geográfica não deve ser confundida com o local de aplicação empírica do estudo. 30

LISTA DE QUADROS

LISTA DE TABELAS

Tabela 1 – Cronograma restante para Defesa 16
Tabela 2 – Análise de riscos do projeto 16
Tabela 3 – Síntese funcional dos 13 artigos do Núcleo A. Valores de desempenho não são comparados porque tarefas, dados, escalas e desenhos de validação diferem entre estudos. 30
Tabela 4 – Resumo dos principais trabalhos revisados 35

SUMÁRIO

1 INTRODUÇÃO 10
1.1 Problema de pesquisa 11
1.1.1 Solução proposta e hipóteses *12*
1.1.2 Delimitação de escopo *12*
1.1.3 Justificativa *13*
1.2 Objetivos 14
1.2.1 Objetivo geral *14*
1.2.2 Objetivos específicos *14*
1.3 Metodologia 15
1.3.1 Metodologia da pesquisa *15*
1.3.2 Procedimentos metodológicos *15*
1.3.3 Cronograma *16*
1.3.4 Análise de riscos *16*
1.4 Estrutura da dissertação 16

2 FUNDAMENTAÇÃO TEÓRICA 18

3 REVISÃO SISTEMÁTICA DA LITERATURA 19
3.1 Introdução 20
3.2 Metodologia 21
3.2.1 Desenho do estudo *21*
3.2.2 Estratégia de busca e elegibilidade *22*
3.2.3 Deduplicação e fluxo de seleção *22*
3.2.4 Triagem temática e validação do procedimento *23*
3.2.5 Escore de priorização *24*
3.2.6 Análise de sensibilidade do escore *25*
3.2.7 Indicadores e mapeamento científico estrutural *26*
3.3 Resultados 27
3.3.1 Composição do corpus *27*
3.3.2 Validação externa de cobertura *27*
3.3.3 Evolução temporal e padrão de citações *28*
3.3.4 Tecnologias e técnicas predominantes *28*
3.3.5 Distribuição geográfica *29*

3.3.6 Síntese dos artigos de maior prioridade *29*
3.4 Discussão 31
3.4.1 Crescimento bibliométrico não equivale à maturidade operacional . *31*
3.4.2 A tarefa científica deve preceder a escolha do algoritmo *32*
3.4.3 Validação, dependência espacial e incerteza *32*
3.4.4 Lacuna costeira, desigualdade de dados e aplicabilidade regional . . *32*
3.4.5 Agenda de pesquisa *33*
3.5 Limitações 33
3.6 Conclusão 34
3.7 Trabalhos relacionados 34

4 ANÁLISE EXPLORATÓRIA DOS DADOS 36

5 RESULTADOS 37

6 CONCLUSÃO 38

Referências 39

CAPÍTULO

1

INTRODUÇÃO

Nas últimas décadas, eventos climáticos extremos têm se intensificado em todo o mundo, como consequência direta das mudanças climáticas globais. Fenômenos como tempestades, enchentes, secas e ondas de calor ocorrem com maior frequência e intensidade, colocando em risco populações vulneráveis e pressionando os sistemas de infraestrutura urbana e ambiental (IPCC, 2021). No Brasil, esse cenário é especialmente preocupante em regiões costeiras, que concentram densos núcleos urbanos, grande valor econômico e significativa exposição a riscos hidrológicos.

O estado de Santa Catarina, em particular, tem vivenciado recorrentes episódios de enchentes, afetando milhares de pessoas e gerando prejuízos socioeconômicos relevantes. Cidades litorâneas combinam fatores geográficos e climáticos que favorecem a ocorrência de inundações, como relevo acidentado, ocupação desordenada e sistemas de drenagem deficitários (BRASIL, 2021).

Nesse contexto, torna-se urgente o desenvolvimento de mecanismos que ampliem a capacidade preditiva desses eventos, de modo a mitigar seus impactos. A aplicação de técnicas de Inteligência Artificial na modelagem de fenômenos hidrológicos vem ganhando destaque na literatura internacional (MOSAVI; OZTURK; CHAU, 2018; ZHANG *et al.*, 2019), demonstrando ganhos de precisão em relação aos métodos estatísticos tradicionais. No entanto, observa-se que a adoção dessas abordagens ainda é limitada em escala regional, especialmente na integração de dados socioeconômicos e geográficos às variáveis ambientais.

Este projeto se insere na interseção entre ciência de dados, gestão ambiental e planejamento urbano, com foco específico na realidade das comunidades costeiras de Santa Catarina. Dentro deste contexto, este trabalho busca contribuir para o avanço da aplicação de técnicas de Inteligência Artificial na previsão de enchentes, visando apoiar a formulação de políticas públicas mais eficazes e aumentar a resiliência das populações frente aos

desastres climáticos.

1.1 Problema de pesquisa

As mudanças climáticas vêm provocando o aumento da frequência e da intensidade de eventos extremos, como chuvas intensas, alagamentos e inundações. Comunidades costeiras, em especial, encontram-se em situação de vulnerabilidade acentuada devido a fatores geográficos, socioeconômicos e de infraestrutura urbana. Apesar da crescente disponibilidade de dados climáticos, hidrológicos e socioambientais, a aplicação prática de modelos preditivos baseados em inteligência computacional para avaliar riscos e antecipar impactos ainda é incipiente, principalmente no contexto regional de Santa Catarina.

A complexidade do problema reside na necessidade de integrar múltiplas fontes de dados – muitas vezes heterogêneas, despadronizadas ou incompletas – e na construção de modelos capazes de gerar previsões não apenas com acurácia, mas também com antecedência suficiente para subsidiar ações preventivas por parte do poder público e da sociedade civil. Além disso, é essencial considerar variáveis socioeconômicas e espaciais para identificar áreas de maior risco e vulnerabilidade social.

Diante desse cenário, este projeto busca responder à seguinte pergunta central:

- Como prever, com maior precisão e antecedência, os impactos de eventos climáticos extremos em comunidades costeiras utilizando técnicas de Inteligência Artificial?

A partir dessa questão norteadora, derivam-se os seguintes questionamentos específicos:

- Quais padrões podem ser extraídos dos dados históricos?
- Quais padrões históricos são detectáveis nos dados sobre eventos extremos nas regiões costeiras de SC?
- Como a Inteligência Artificial pode ser aplicada para prever eventos de forma precisa e antecipada?
- Como identificar, com base em dados, as áreas e populações mais vulneráveis a esses impactos?

Essas questões fundamentam o desenvolvimento do modelo preditivo e sustentam as hipóteses que serão testadas na próxima seção.

1.1.1 Solução proposta e hipóteses

A solução proposta neste projeto consiste no desenvolvimento de um modelo preditivo baseado em técnicas de inteligência artificial, com o objetivo de antecipar a ocorrência e os impactos de eventos climáticos extremos em comunidades costeiras do estado de Santa Catarina. Este modelo será projetado para integrar dados de natureza diversa, incluindo variáveis climáticas (como precipitação e temperatura), hidrológicas (níveis de rios e vazões) e socioeconômicas (densidade populacional, índice de vulnerabilidade social, infraestrutura urbana, entre outros). A abordagem adotada busca oferecer previsões mais precisas, localizadas e contextualizadas, indo além das limitações dos modelos puramente físicos ou estatísticos tradicionais.

A proposta contempla a construção de uma base de dados integrada, a seleção e o treinamento de algoritmos de aprendizado de máquina adequados à modelagem temporal e espacial dos eventos, bem como a validação dos resultados com base em registros históricos e dados reais de campo. Espera-se que o modelo desenvolvido possa identificar padrões preditivos relevantes, contribuir para a redução da vulnerabilidade das populações afetadas e subsidiar a formulação de políticas públicas e estratégias de mitigação mais eficazes.

No entanto, a solução apresenta algumas limitações. O modelo não será projetado para operar em tempo real, nem substituirá sistemas operacionais oficiais de alerta. Além disso, a precisão das previsões dependerá da qualidade, abrangência e atualização dos dados utilizados, o que exige atenção constante durante a fase de coleta e tratamento.

Com base na proposta apresentada, formulam-se as seguintes hipóteses de pesquisa:

- A Inteligência Artificial melhora significativamente a precisão da previsão de enchentes;
- A inclusão de variáveis socioeconômicas permite identificar áreas críticas com mais eficácia;

Essas hipóteses nortearão o desenvolvimento da metodologia e serão verificadas ao longo da implementação do projeto.

1.1.2 Delimitação de escopo

Este projeto de pesquisa está delimitado à aplicação de modelos preditivos baseados em inteligência artificial voltados à previsão de eventos climáticos extremos em regiões costeiras do estado de Santa Catarina. A proposta contempla o uso de dados

públicos e abertos, incluindo informações climáticas, hidrológicas, geográficas e socioeconômicas, provenientes de fontes oficiais e acessíveis, como institutos meteorológicos, bases governamentais e imagens de satélite.

A abordagem metodológica estará focada na construção e avaliação de modelos preditivos, com a realização de testes utilizando dados históricos e reais da região de estudo. Pretende-se investigar a eficácia de diferentes algoritmos de aprendizado de máquina, assim como o impacto da inclusão de variáveis socioeconômicas na qualidade das previsões.

Estão incluídos no escopo do projeto:

- Regiões costeiras de SC;
- Dados públicos, modelos preditivos com IA;
- Dados abertos climáticos e geográficos;
- Testes com dados reais;

Estão fora do escopo do projeto:

- A construção de sistemas operacionais para uso em tempo real, como sistemas de alerta imediato;
- A aplicação ou generalização dos modelos para regiões fora do estado de Santa Catarina;

Ao estabelecer essas delimitações, busca-se garantir a viabilidade técnica e científica do projeto, concentrando esforços no desenvolvimento de um modelo conceitualmente robusto, testado com dados reais e aplicável ao contexto regional de interesse.

1.1.3 Justificativa

A intensificação dos eventos climáticos extremos, como chuvas intensas, enchentes e alagamentos, tem provocado impactos significativos em comunidades vulneráveis, especialmente nas regiões costeiras. Segundo o Painel Intergovernamental sobre Mudanças Climáticas, a tendência global é de aumento na frequência e severidade desses eventos, exigindo respostas mais eficazes e baseadas em dados. No estado de Santa Catarina, esses impactos já são recorrentes e causam prejuízos materiais, deslocamento de populações e ameaças à vida humana e ao meio ambiente.

Diante desse cenário, torna-se urgente o desenvolvimento de soluções tecnológicas que permitam antecipar com precisão os riscos e impactos associados a esses fenômenos. A proposta deste projeto se justifica pela capacidade das técnicas de inteligência artificial

de processar grandes volumes de dados ambientais, climáticos e socioeconômicos, identificando padrões complexos que escapam às abordagens tradicionais. Além disso, modelos de aprendizado de máquina vêm apresentando resultados promissores na previsão de fenômenos hidrológicos, com destaque para sua capacidade de adaptação a cenários não lineares e de alta variabilidade (MOSAVI; OZTURK; CHAU, 2018; OLIVEIRA; MARTINS; MENDIONDO, 2013).

O diferencial deste projeto está na integração de dados geoespaciais e socioeconômicos aos modelos climáticos, algo ainda pouco explorado na literatura nacional, especialmente em aplicações regionais voltadas à realidade das comunidades costeiras de Santa Catarina. A maioria das abordagens atuais concentra-se em modelos hidrológicos baseados apenas em variáveis físicas e climáticas, desconsiderando o contexto social e a infraestrutura das áreas afetadas.

Além da relevância científica, a proposta apresenta viabilidade técnica e aplicabilidade prática, uma vez que se baseia em dados públicos e acessíveis, além de utilizar ferramentas computacionais já consolidadas na área de ciência de dados. Os resultados esperados têm potencial para subsidiar ações de planejamento urbano, defesa civil e políticas públicas voltadas à redução de riscos, contribuindo para o fortalecimento da resiliência local frente às mudanças climáticas.

1.2 Objetivos

1.2.1 Objetivo geral

Desenvolver um modelo preditivo baseado em Inteligência Artificial para compreender e prever impactos de eventos extremos em regiões costeiras de SC.

1.2.2 Objetivos específicos

1. Consolidar um banco de dados a ser estruturado a partir de compilação de dados de satélite, sensores ambientais e registros históricos de enchentes nas regiões costeiras do estado de Santa Catarina;

2. Analisar as características ambientais associadas aos eventos históricos de enchentes nas regiões costeiras de Santa Catarina;

3. Implementar modelos de aprendizado de máquina que aprendam com os padrões ambientais históricos e possibilitem construir potenciais cenários de previsão à luz das incertezas existentes;

4. Projetar para o futuro, com base nos dados de projeções climáticas baseadas nos modelos e cenários definidos pelo Painel Intergovernamental sobre Mudanças Climá-

ticas das Nações Unidas quais serão os potenciais padrões de enchentes esperados para as regiões costeiras do estado de Santa Catarina.

1.3 Metodologia

1.3.1 Metodologia da pesquisa

A pesquisa proposta adota o método hipotético-dedutivo, pois parte de hipóteses formuladas com base na literatura existente, que serão testadas e validadas ao longo da execução do projeto. Trata-se de uma pesquisa aplicada, uma vez que visa solucionar um problema concreto relacionado à previsão de eventos extremos e seus impactos em comunidades costeiras. A abordagem é quantitativa, pois envolve a coleta, análise e modelagem de dados numéricos em larga escala, com uso de algoritmos matemáticos e computacionais. Quanto aos objetivos, a pesquisa é exploratória, ao investigar possibilidades tecnológicas de aplicação da inteligência artificial; descritiva, ao levantar e analisar padrões históricos de enchentes; e explicativa, ao buscar compreender relações causais entre variáveis ambientais e impactos sociais.

A escolha desse conjunto metodológico justifica-se pela complexidade e natureza multidisciplinar do problema abordado, que exige uma abordagem estruturada, rigorosa e orientada por dados para gerar conhecimento aplicável e reproduzível.

1.3.2 Procedimentos metodológicos

A condução da pesquisa seguirá as seguintes etapas e técnicas:

- **Pesquisa bibliográfica:** levantamento e análise de estudos científicos sobre uso de inteligência artificial em hidrologia, previsão de desastres e gestão de riscos.
- **Pesquisa documental:** análise de relatórios técnicos, dados públicos e registros históricos de eventos extremos em Santa Catarina.
- **Levantamento e organização de dados:** compilação de informações climáticas, hidrológicas, socioeconômicas e geográficas a partir de bases abertas e oficiais.
- **Modelagem preditiva com inteligência artificial:** desenvolvimento de modelos com diferentes algoritmos (ex: redes neurais artificiais, LSTM, árvores de decisão).
- **Validação empírica:** testes dos modelos com dados históricos para verificar acurácia, sensibilidade e aplicabilidade prática.

1.3.3 Cronograma

Tabela 1 – Cronograma restante para Defesa

Atividade	**M19**	**M20**	**M21**	**M22**	**M23**	**M24**
Levantamento bibliográfico	X	X	X	X	X	
Coleta e organização dos dados	X					
Análise exploratória dos dados	X					
Implementação do modelo		X	X			
Validação e testes			X	X		
Escrita da dissertação				X	X	
Defesa						X

Fonte: Elaborado pela autora.

1.3.4 Análise de riscos

Tabela 2 – Análise de riscos do projeto

Risco potencial	**Prob.**	**Impacto**	**Gatilho**	**Plano de contingência**
Falta de dados históricos completos	Média	Alta	Dados incompletos ou inconsistentes	Buscar fontes alternativas, interpolação e limpeza de dados
Baixa performance dos modelos de Inteligência Artificial	Média	Média	Alto erro ou baixa precisão	Testar algoritmos alternativos, ajustar hiperparâmetros
Dificuldade na integração de dados heterogêneos	Alta	Média	Inconsistências entre fontes	Uso de ferramentas de ETL e padronização
Mudanças na disponibilidade de bases públicas	Baixa	Média	Remoção de acesso a APIs ou sites	Armazenar backups locais, antecipar coleta de dados
Atraso no cronograma devido à complexidade	Média	Alta	Atividades técnicas levarem mais tempo	Reorganizar etapas e priorizar entregas parciais

Fonte: Elaborado pela autora.

1.4 Estrutura da dissertação

O Capítulo 1, Introdução, apresentou a contextualização do tema, o problema de pesquisa, a solução proposta, as hipóteses, a delimitação do escopo, a justificativa, os objetivos e a metodologia da pesquisa.

O Capítulo 2 apresenta a fundamentação teórica sobre inteligência artificial aplicada à previsão de enchentes e à avaliação de vulnerabilidade de comunidades costeiras.

O Capítulo 3 apresenta a revisão sistemática da literatura, na forma de uma análise cientométrica multibase conduzida segundo o protocolo PRISMA, e os trabalhos relacionados.

O Capítulo 4 apresenta a análise exploratória dos dados das bases utilizadas nessa dissertação, com a junção de objetivos 1 e 2 desse referido manuscrito.

O Capítulo 5 apresenta e analisa os resultados obtidos.

O Capítulo 6 apresenta as considerações finais, as contribuições do estudo e os trabalhos futuros.

CAPÍTULO

2

FUNDAMENTAÇÃO TEÓRICA

Capítulo a escrever: conceitos de hidrologia e inundações, aprendizado de máquina (RNA, LSTM, árvores de decisão), índices de vulnerabilidade e dados geoespaciais.

CAPÍTULO

3

REVISÃO SISTEMÁTICA DA LITERATURA

Este capítulo apresenta o artigo submetido ao SEPOC, *Aplicações de inteligência artificial na previsão e no mapeamento de inundações: uma análise cientométrica multibase*, seguido dos trabalhos relacionados.

Resumo do artigo

A aplicação de Inteligência Artificial (IA) a inundações abrange problemas distintos, incluindo previsão hidrológica, detecção de áreas inundadas, mapeamento de suscetibilidade e avaliação de risco. Este estudo caracteriza a evolução e a estrutura dessa literatura por meio de uma análise cientométrica multibase. Foram identificados 16.845 registros nas exportações da Lens.org, Scopus, IEEE Xplore e SciELO; após deduplicação e filtragem temática automatizada, 2.068 artigos compuseram o corpus analisado, estratificados por um escore composto de priorização; 13 integraram o estrato de maior prioridade analítica. O fluxo foi reproduzido por reexecução do código sobre os arquivos brutos, e suas regras, falhas e sensibilidade são documentadas. A triagem não envolveu avaliação manual registro a registro; sua validade foi examinada por análise de sensibilidade e por comparação com as referências de uma revisão sistemática independente, que revelou recuperação parcial da literatura central. O rótulo do estrato de maior prioridade mostrou-se dependente da composição do corpus, enquanto a posição no ranking foi mais estável. A produção aumentou fortemente após 2018 e alcançou 578 artigos em 2025, enquanto 2019–2025 concentrou aproximadamente 93,3% do corpus selecionado. As palavras-chave indicaram expansão de *deep learning*, LSTM, CNN e métodos *ensemble*, embora Random Forest e SVM permaneçam relevantes, sobretudo em aplicações espaciais. China, Estados Unidos e Índia lideraram a produção por afiliação. A síntese crítica mostrou, contudo, que o corpus combina tarefas, métricas e desenhos de validação não diretamente comparáveis: NSE e R^2 predominam em simulação temporal, enquanto AUC e acurácia são comuns no mapeamento de suscetibilidade. Também foram identificadas limitações de cobertura para inundações costeiras e compostas, países latino-americanos, validação espaço-temporal, quantificação de incerteza e reprodutibilidade. Conclui-se que o avanço do campo depende menos da simples adoção de arquiteturas mais com-

plexas e mais de avaliações fora da amostra, integração com conhecimento hidrológico, dados abertos e sistemas operacionais de alerta.

Index Terms—inteligência artificial, previsão de inundações, suscetibilidade a inundações, inundações urbanas, inundações costeiras, cientometria.

3.1 Introdução

Inundações resultam da interação entre forçantes meteorológicas e oceânicas, características da bacia, uso do solo, capacidade de drenagem, exposição e vulnerabilidade. Embora a intensificação da precipitação extrema e a elevação do nível do mar ampliem riscos em diversas regiões, principalmente costeiras, tendências observadas de inundação não são espacialmente uniformes e também dependem de urbanização (impermeabilização do solo), intervenções hidráulicas e mudanças na ocupação territorial (IPCC, 2022; WAHL *et al.*, 2015). Em cidades costeiras, a coincidência entre chuva intensa, descarga fluvial e maré elevada pode produzir eventos compostos mais severos do que aqueles gerados por um único processo (WAHL *et al.*, 2015).

Modelos hidrológicos, hidráulicos e hidrodinâmicos continuam essenciais para representar mecanismos físicos e testar cenários. Entretanto, sua aplicação operacional pode ser limitada por custo computacional, disponibilidade de dados, calibração local e dificuldade de representar relações não lineares em alta dimensão. Métodos de *machine learning* (ML) e *deep learning* (DL) têm sido utilizados como modelos substitutos, ferramentas de pós-processamento ou componentes híbridos, com aplicações em previsão de chuva/vazão, delimitação de áreas inundadas, classificação de suscetibilidade e sistemas de alerta (MOSAVI; OZTURK; CHAU, 2018; SHEN, 2018; KRATZERT *et al.*, 2018; NEARING *et al.*, 2021). Resultados recentes demonstram, inclusive, a viabilidade de previsões globais de eventos fluviais extremos em bacias não monitoradas, com modelos treinados em grandes conjuntos de dados (NEARING *et al.*, 2024).

O crescimento acelerado do campo dificulta distinguir tendências tecnológicas robustas de efeitos de popularidade, cobertura de base e atraso de citação. Além disso, expressões como “previsão de inundação”, “mapeamento de suscetibilidade”, “detecção de inundação” e “avaliação de risco” representam tarefas científicas diferentes e não devem ser avaliadas pelas mesmas métricas. Análises cientométricas permitem mapear a estrutura de um domínio, desde que a busca, a deduplicação, as unidades de contagem e as limitações de cobertura sejam explicitadas (ARIA; CUCCURULLO, 2017). Recomendações de transparência de revisões estruturadas, como o PRISMA, também são úteis para documentar identificação, triagem e inclusão de registros, ainda que o presente estudo não constitua uma revisão de efeitos de intervenção (PAGE *et al.*, 2021).

Parecer SEPOC – originalidade

A originalidade do estudo também deve ser mais claramente estabelecida em relação a revisões anteriores de previsão de inundações baseada em IA, especialmente porque o próprio manuscrito cita uma revisão sistemática sobre modelos de previsão de inundações publicada na SEPOC 2025.

Ação realizada

Parágrafo reescrito com o que Dias *et al.* (2025) de fato fizeram (32 estudos, PRISMA, taxonomia de técnicas, sem análise bibliométrica) e com a diferença real. A frase anterior ("uma única tarefa hidrológica linear") não correspondia ao artigo e foi removida. As referências internacionais do Dias passam a servir de validação externa de cobertura (Seção 3.3.2).

Revisões sistemáticas recentes sintetizaram técnicas de previsão de inundações. Dias *et al.* (2025), por exemplo, analisaram 32 estudos, selecionados de 433 registros conforme o PRISMA, e organizaram uma taxonomia de métodos estatísticos, de *machine learning*, de *deep learning* e híbridos, incluindo sistemas com IoT. O presente estudo é complementar, e não substitutivo: em vez de sintetizar qualitativamente um conjunto reduzido de estudos, mapeia de forma cientométrica um corpus de 2.068 artigos recuperados em três bases, estratifica-o por tarefa científica (previsão, detecção, suscetibilidade e risco) e examina lacunas de cobertura, em particular as costeiras e compostas, que não foram o foco da revisão anterior. Além disso, as referências internacionais de Dias *et al.* (2025) são empregadas como referência externa para avaliar a cobertura da busca e do escore aqui adotados.

Com base neste contexto, este artigo busca responder a três perguntas: (i) como a produção científica sobre IA e inundações evoluiu temporal e geograficamente? (ii) quais famílias de métodos e tarefas dominam o corpus? e (iii) quais lacunas metodológicas e geográficas limitam a transferência dos resultados para aplicações operacionais, urbanas e costeiras? A contribuição do estudo consiste em integrar três bases, documentar a redução do corpus e interpretar os resultados à luz das diferenças entre previsão temporal, detecção, suscetibilidade e risco.

3.2 Metodologia

3.2.1 Desenho do estudo

Foi realizada uma análise cientométrica descritiva, complementada por síntese narrativa dos artigos de maior prioridade. O fluxo de identificação e seleção foi apresentado segundo o formato de relato do PRISMA (PAGE *et al.*, 2021), o que organiza a documentação das etapas, mas não implica uma revisão sistemática com triagem manual por pares: a seleção foi automatizada e é descrita na Seção 3.2.4. Os indicadores bibliomé-

tricos seguiram práticas de harmonização e mapeamento científico descritas por Aria e Cuccurullo (2017).

3.2.2 Estratégia de busca e elegibilidade

As buscas foram conduzidas nas bases Lens.org, Scopus, IEEE Xplore e SciELO, abrangendo publicações de 1992 a 2026, sendo 2026 um ano parcial. A expressão original, adaptada apenas à sintaxe de cada plataforma, foi:

> (“flood prediction” OR “flood forecasting” OR “flood risk” OR “flood modeling” OR “urban flooding” OR “inundation”) AND (“machine learning” OR “deep learning” OR “artificial intelligence”).

Os critérios de elegibilidade foram implementados como regras de correspondência de termos, por busca de trechos de texto sem distinção de caixa, sobre título, resumo e palavras-chave. Foram retidos os registros que continham, simultaneamente: (i) ao menos um de 18 termos de inundação ou previsão (por exemplo, *flood prediction*, *flood forecasting*, *flood risk*, *flooding*, “inundação urbana”); (ii) ao menos um de 20 termos de IA/ML (por exemplo, *machine learning*, *deep learning*, LSTM, *random forest*, *ensemble*); e (iii) ao menos um de 40 termos de dados hidrológicos ou geoespaciais no resumo ou nas palavras-chave (por exemplo, *rainfall*, *river*, *satellite*, *remote sensing*). Foram excluídos os registros cujo título ou resumo continha algum de 15 termos de exclusão (por exemplo, *flood insurance*, *flood myth*, *buffer overflow*, *dam*, *levee*). Como o casamento é por trecho de texto, termos curtos casam dentro de outras palavras (*dam* em *damage*); esse efeito é quantificado na Seção 3.2.6. As listas completas e o código estão no material suplementar de replicação.

A expressão de busca não incluiu explicitamente termos como *coastal flooding*, *storm surge*, *compound flooding*, *pluvial flooding* e *flash-flood nowcasting*. Essa decisão afeta a sensibilidade da busca para estudos costeiros e compostos e é tratada como limitação, não como evidência de ausência da literatura.

3.2.3 Deduplicação e fluxo de seleção

Foram identificados 16.845 registros, correspondentes à soma de oito arquivos de exportação (Lens em inglês e em português; Scopus, em três arquivos, dois deles com sobreposição de conteúdo por serem exportações com e sem filtro da plataforma; IEEE Xplore, com 612 registros; e SciELO em inglês e em português). Esse total, portanto, é uma contagem de registros nos arquivos e não de documentos distintos. A deduplicação ocorreu em duas etapas. Na primeira, por DOI, restaram 12.470 registros: foram removidos 4.375, dos quais 3.836 eram duplicatas e 539 eram registros sem DOI, que o procedimento

descarta por manter apenas linhas com DOI. Na segunda, por título normalizado quanto à caixa, foram removidos 923, restando 11.547 registros únicos. A reexecução do código reproduziu esses totais (removidos: 5.298), mas não a divisão entre etapas registrada originalmente (4.233 por DOI e 1.065 por título).

Duas limitações de implementação afetaram a composição do corpus. Primeiro, o mapeamento de colunas não reconheceu os campos de título do IEEE Xplore ("Document Title") nem os campos de ano, resumo, palavras-chave e DOI da SciELO em inglês; os registros sem título receberam o rótulo "Unknown" e colapsaram na deduplicação por título, e os sem DOI foram descartados, de modo que, na prática, o corpus provém da Lens e da Scopus. Segundo, a coluna de palavras-chave da Scopus não foi reconhecida, e a elegibilidade desses registros apoiou-se em título e resumo. Ambos os pontos são tratados como limitações (Seção 3.5).

3.2.4 Triagem temática e validação do procedimento

Parecer SEPOC – transparência da seleção

O procedimento de seleção da literatura também requer maior transparência metodológica. Os autores afirmam que o processo de identificação e seleção foi organizado de acordo com os princípios de transparência do PRISMA, mas um fluxograma PRISMA padrão não é fornecido e o procedimento de triagem está insuficientemente documentado. Em particular, 9.479 registros foram excluídos durante a filtragem temática, reduzindo o corpus de 11.547 registros únicos para 2.068 estudos elegíveis, mas o manuscrito não explica claramente como essa triagem foi realizada, se foi manual ou automatizada, quantos revisores estiveram envolvidos, como os desacordos foram tratados ou como as decisões de elegibilidade foram validadas. Considerando o papel central da seleção do corpus em um estudo cientométrico, isso limita a reprodutibilidade da análise.

Resposta ao parecer

A triagem foi **automatizada**, por regras de correspondência de termos; **nenhum revisor humano** avaliou os registros um a um, portanto não há desacordos nem concordância inter-avaliadores a reportar (o trecho anterior sobre auditoria cega e $\kappa = 0{,}91$ foi removido por não ter respaldo em registro algum). A validade é sustentada por replicação, sensibilidade e validação externa (esta Seção e Seção 3.3.2).

A triagem temática dos registros únicos foi inteiramente automatizada, por regras de correspondência de termos nos metadados, implementadas em código, disponibilizado como notebook de replicação (material suplementar)

inserir URL do notebook no repositório

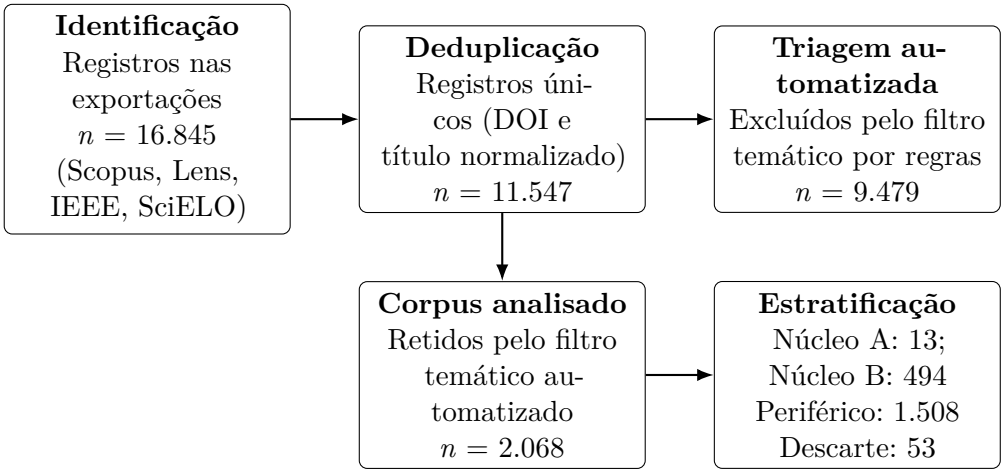
. Não houve avaliação manual de elegibilidade registro a registro nem dupla revisão independente. Por essa razão, não se reportam estatísticas de concordância entre avalia-

dores, como o κ de Cohen, e a decisão de elegibilidade é plenamente determinada pelas regras descritas, o que a torna reprodutível, mas também sujeita aos limites de uma correspondência lexical (sinônimos não previstos são perdidos e termos polissêmicos podem ser aceitos). Esses limites são avaliados por três verificações: (i) reexecução do código original sobre os arquivos brutos, que reproduziu exatamente as contagens do fluxo (16.845, 11.547, 2.068) e dos estratos, e permitiu identificar suas falhas; (ii) análise de sensibilidade do escore (Seção 3.2.6); e (iii) validação externa de cobertura frente às referências de Dias *et al.* (2025) (Seção 3.3.2). Adicionalmente, a elegibilidade dos 13 artigos do Núcleo A foi conferida manualmente pela autora contra quatro critérios explícitos (inundação, IA/ML, previsão ou mapeamento e uso de dados hidrológicos ou geoespaciais)

concluir a conferência dos itens sinalizados: #2 (sem menção a inundação nos metadados), #1, #3 e #12 (escopo), #7 (resumo ausente na base)

. O fluxo de redução é apresentado na Figura 1.

Figura 1 – Fluxo de identificação, deduplicação, triagem automatizada e estratificação do corpus, no formato de relato do PRISMA. A triagem foi automatizada, sem avaliação manual por revisores. O total de 16.845 soma as exportações (inclui duas exportações sobrepostas da Scopus). Todos os valores foram reproduzidos pela reexecução do código sobre os arquivos brutos; entre os 16.845 e os 11.547 estão 539 registros sem DOI descartados.



Fonte: Elaborado pelos autores.

3.2.5 Escore de priorização

Parecer SEPOC – priorização dos 13 artigos

Outra preocupação reside no procedimento de priorização utilizado para selecionar os 13 artigos principais (Core A). A pontuação proposta combina citações, atualidade, aderência temática e articulação entre dados, método e resultados, utilizando pesos predefinidos. Alguns desses componentes envolvem julgamento subjetivo, mas o manuscrito não fornece detalhes suficientes sobre o procedimento de codificação, a concordância entre os revisores

ou a análise de sensibilidade para demonstrar a robustez dessa classificação.

Resposta ao parecer

Os componentes não dependem de julgamento humano: T^* e A^* são calculados por presença de termos (sem codificadores, portanto sem concordância a medir); a regra é descrita abaixo e a robustez é testada na Seção 3.2.6. Foi removida a "rubrica de hiperparâmetros e reprodutibilidade dos protocolos de treino", que não correspondia ao cálculo realizado.

Para ordenar a leitura, foi empregado um escore composto para cada artigo i:

$$S_i = 0{,}35\,C_i^* + 0{,}20\,R_i^* + 0{,}30\,T_i^* + 0{,}15\,A_i^*, \tag{3.1}$$

em que C_i^* são as citações normalizadas por mínimo e máximo no corpus (de 0 a 555), $R_i^* = (\text{ano}_i - 1992)/(2026 - 1992)$ é a recência, T_i^* é a aderência temática e A_i^* é a aderência a dados, método e resultado. As regras de T^* e A^* são determinísticas, baseadas em listas de termos: $T^* = 1{,}0$ se o título contém um termo de inundação ou previsão e um termo de IA/ML; $T^* = 0{,}7$ se essa coocorrência ocorre apenas no conjunto de título, resumo e palavras-chave; e $T^* = 0{,}4$ nos demais casos (nenhum registro recebeu 0,4, pois o filtro já exige a coocorrência; 514 registros tiveram $T^* = 1{,}0$ e 1.554 tiveram 0,7). $A^* = (I + M + O + C)/4$, em que I vale 1 se o resumo ou as palavras-chave contêm termo de dados hidrológicos ou geoespaciais e 0 caso contrário (vale 1 para todo o corpus, pois o filtro já exige esse termo); M vale 1 se título ou resumo contêm termo de método específico (por exemplo, LSTM, CNN, *random forest*) e 0,5 caso contrário; O vale 1 se título ou resumo mencionam previsão, alerta ou mapeamento e 0,5 caso contrário; e C vale 1 se o resumo ou as palavras-chave mencionam contexto urbano, costeiro, de bacia ou de rio e 0,5 caso contrário. Assim, A^* variou de 0,625 a 1. Não há julgamento humano nessas regras. O escore final foi reescalado por mínimo e máximo para 0–100; assim, o valor 100 corresponde ao artigo de maior escore dentro do corpus e não a um padrão absoluto de qualidade, e os cortes (Núcleo A ≥ 70; Núcleo B de 50 a 70; Periférico de 30 a 50; Descarte < 30) são relativos a este corpus.

3.2.6 Análise de sensibilidade do escore

Como os pesos foram definidos a priori, testou-se a estabilidade do Núcleo A frente a variações dos pesos, recalculando o escore sobre os mesmos 2.068 artigos (componentes C^*, R^*, T^* e A^* fixos). Em 10.000 simulações, cada peso foi multiplicado por um fator independente entre 0,85 e 1,15, com renormalização para soma 1. Em todas as simulações, ao menos 11 dos 13 artigos originais permaneceram entre os 13 primeiros do ranking (média de 12,2; os 13 permaneceram em 24,8% das simulações). A variação de um único peso em $\pm 15\%$ manteve 12 ou 13 artigos, e pesos iguais para os quatro componentes mantiveram 11. A classificação é, portanto, robusta a perturbações moderadas, mas não

a mudanças grandes: sorteando pesos de uma distribuição de Dirichlet com concentração 5, a média de retenção caiu para 9,1 artigos e apenas 35,6% das simulações mantiveram 11 ou mais. Além disso, o corte fixo em 70 pontos é frágil: quatro artigos têm escore entre 70,2 e 71,1, logo acima do corte, e o tamanho do Núcleo A variou de 7 a 45 artigos nas simulações de ±15%. Por essa razão, o ranking relativo é mais defensável do que o corte absoluto.

A estabilidade foi testada também frente à composição do corpus. A exclusão por trecho de texto remove artigos pertinentes: dos 2.694 registros que satisfaziam os demais critérios, 626 foram excluídos e 498 deles apenas porque um termo curto de exclusão (*dam*) aparecia dentro de outra palavra (*damage*), entre eles Mosavi, Ozturk e Chau (2018), revisão de previsão de inundações com ML e 1.008 citações. Refazendo o fluxo com a exclusão restrita a palavras inteiras (corpus de 2.566 registros, demais regras idênticas), o artigo de Mosavi et al. entra no corpus e o máximo de citações passa de 555 para 1.008; como C^* é normalizado pelo máximo, os escores dos demais diminuem, e apenas esse artigo atinge 70 pontos. Os 13 artigos originais passam a ter de 49 a 63 pontos (Núcleo B). Em posição no ranking, porém, 12 dos 13 permanecem entre as 25 primeiras de 2.566 (posições 5 a 25), e um (o estudo de detecção e suscetibilidade com Sentinel-1) cai para a 401.ª. O rótulo "Núcleo A" é, portanto, uma propriedade do corpus e do artigo mais citado, e não uma classe estável; o ranking é a evidência mais defensável de prioridade, e os 13 artigos devem ser entendidos como o topo do ranking do procedimento original, e não como um conjunto invariante.

3.2.7 Indicadores e mapeamento científico estrutural

Parecer SEPOC – contribuição científica

Contudo, a contribuição científica ainda é limitada em sua forma atual. Embora o corpus inicial seja extenso, a maior parte da análise cientométrica baseia-se em indicadores descritivos, como número de publicações, frequência de citações, palavras-chave, categorias tecnológicas e países de afiliação. Análises mais consolidadas de mapeamento científico, como redes de coocorrência, análise de cocitação, acoplamento bibliográfico ou evolução temática, não são apresentadas.

Resposta ao parecer

Foi retirada a afirmação de que a rede de coocorrência mapeava "evolução e acoplamento dos clusters", pois isso não foi feito. O estudo declara-se descritivo, apresenta a coocorrência de palavras-chave que existe e registra cocitação, acoplamento e evolução temática como agenda. Alternativa, se houver tempo: executar o script `bibliometrix` do repositório e documentar o resultado.

Foram analisados indicadores bibliométricos descritivos fundamentais, incluindo o número anual de artigos, distribuição de citações por ano, frequência de categorias

tecnológicas e países de afiliação. As frequências de palavras-chave foram complementadas por uma rede de coocorrência dos 31 termos tecnológicos mais frequentes (203 pares), que resultou em um único agrupamento, sem separação temática interna

inserir a figura da rede de coocorrência do repositório (pasta 07_palavras_chave)

. Não foram realizadas, neste estudo, análises de cocitação, de acoplamento bibliográfico nem de evolução temática; o caráter descritivo do trabalho é declarado como limitação e essas análises compõem a agenda de continuidade. Contagens geográficas representam afiliações presentes nos metadados, não necessariamente o local empírico do estudo. As citações correspondem ao estado das bases na data de extração e estão sujeitas a diferenças de cobertura e atraso de acumulação.

3.3 Resultados

3.3.1 Composição do corpus

A deduplicação reteve 68,5% dos 16.845 registros inicialmente identificados. Após a filtragem temática automatizada, 2.068 documentos permaneceram para a análise, equivalentes a 17,9% dos registros únicos. O Núcleo A correspondeu a 0,63% do corpus analisado, enquanto os Núcleos A e B, em conjunto, reuniram 507 documentos (24,5%). Esses percentuais descrevem a intensidade da triagem, não sua validade, examinada na Seção 3.3.2.

3.3.2 Validação externa de cobertura

Como não houve avaliação manual da triagem, a cobertura do procedimento foi testada contra um conjunto independente: as 22 referências internacionais de Dias *et al.* (2025), selecionadas por uma revisão sistemática segundo o PRISMA (as 10 demais referências são dissertações, relatórios e literatura cinzenta nacional, fora do alcance das bases consultadas). Os títulos foram localizados por similaridade textual ($\geq 0{,}90$) nos 16.845 registros brutos e acompanhados ao longo do fluxo. Dez das 22 (45%) foram localizadas; oito passaram no filtro temático, três delas foram barradas por termos de exclusão (entre as quais Mosavi, Ozturk e Chau (2018), por *dam* em *damage*) e cinco chegaram ao corpus de 2.068 artigos, sendo quatro no Núcleo B e uma no estrato Periférico; nenhuma integrou o Núcleo A. Doze não foram localizadas; parte delas pode estar nos arquivos do IEEE Xplore, cujo campo de título não foi lido pelo código, o que impede a comparação por título. Assim, as perdas ocorrem em dois pontos: na busca e na recuperação (doze referências) e no filtro, por limitação de implementação (duas fora do filtro e três por termo de exclusão).

Esse resultado indica que o escore prioriza de forma consistente o que o corpus contém, mas que a cobertura da literatura central é parcial, sobretudo por limitações da

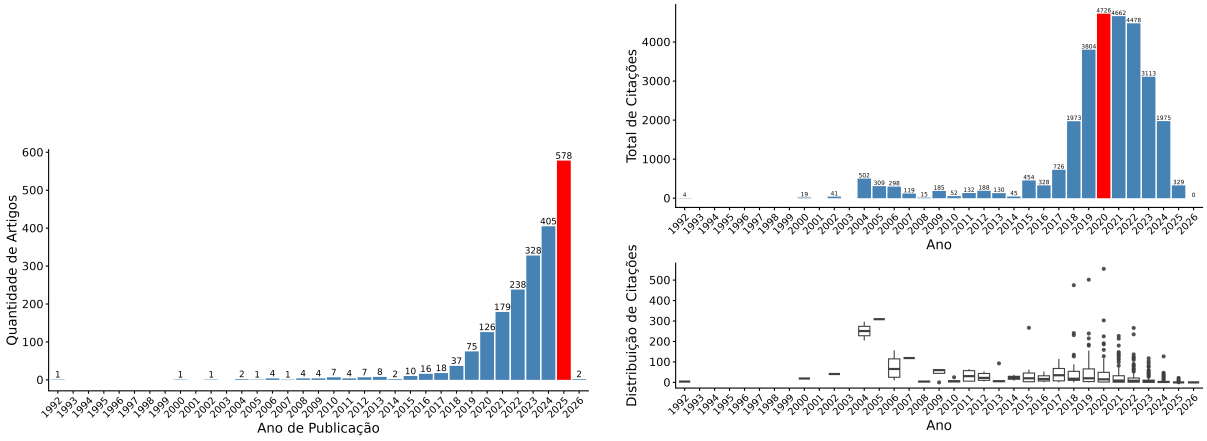
estratégia de busca. Ele não invalida o mapeamento, mas condiciona sua interpretação: os 13 artigos do Núcleo A são os de maior prioridade *dentro do corpus recuperado*, e não necessariamente os mais relevantes da literatura.

3.3.3 Evolução temporal e padrão de citações

A produção aumentou acentuadamente a partir de 2018. O ano de 2025 reuniu 578 artigos, ou 28,0% do corpus elegível, e o intervalo 2019–2025 concentrou aproximadamente 93,3% das publicações. O valor de 2026 não deve ser comparado aos anos completos devido à extração parcial e ao atraso de indexação (Figura 2a).

A distribuição de citações foi fortemente assimétrica, com poucos artigos concentrando uma grande parcela do impacto observado (Figura 2b). Os totais mais elevados nas coortes intermediárias refletem simultaneamente a visibilidade e o tempo de exposição. Consequentemente, as citações brutas favorecem documentos mais antigos, enquanto os anos recentes ainda não completaram sua janela de acumulação.

Figura 2 – Dinâmica temporal do corpus selecionado. Em (a), 2026 representa um ano parcial. Em (b), as citações são apresentadas em escala bruta e refletem a data de extração, a cobertura das bases e o tempo de acumulação.



(a) Produção anual

(b) Citações por ano

Fonte: Elaborado pelos autores.

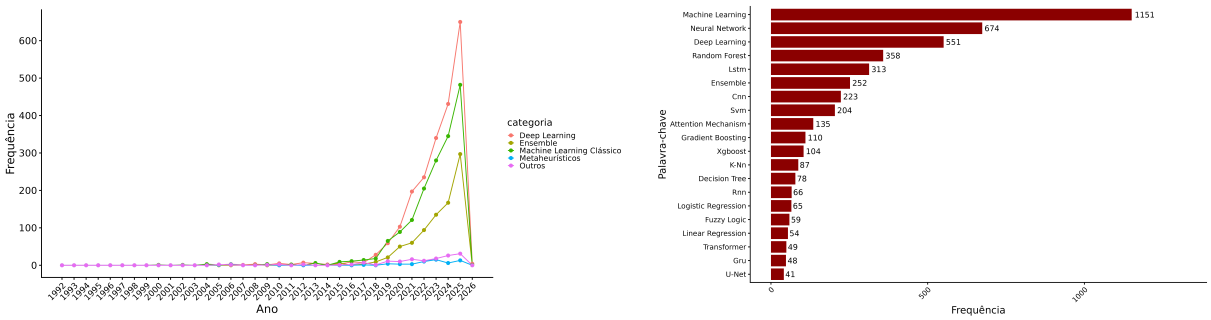
3.3.4 Tecnologias e técnicas predominantes

As categorias de DL apresentaram o crescimento mais rápido após 2018, acompanhadas por ML clássico e métodos *ensemble* (Figura 3a). Como as categorias são não excludentes, as frequências anuais podem superar o número de documentos do mesmo ano. A queda observada em 2026 é artefato do período parcial.

Machine learning foi o termo mais frequente (1.151 ocorrências), seguido por *neural network* (674), *deep learning* (551), Random Forest (358), LSTM (313), *ensemble* (252),

CNN (223) e SVM (204) (Figura 3b). Transformers e GRU apresentaram frequências menores, compatíveis com tecnologias emergentes no período analisado. A persistência de Random Forest e SVM sugere que métodos clássicos continuam competitivos em bases de dados tabulares e em tarefas de classificação espacial, nas quais interpretabilidade, amostras moderadas e custo computacional permanecem relevantes.

Figura 3 – Perfil tecnológico do corpus. As contagens são frequências de ocorrência em metadados harmonizados e não representam conjuntos mutuamente exclusivos de artigos.



(a) Categorias tecnológicas

(b) Técnicas e termos mais frequentes

Fonte: Elaborado pelos autores.

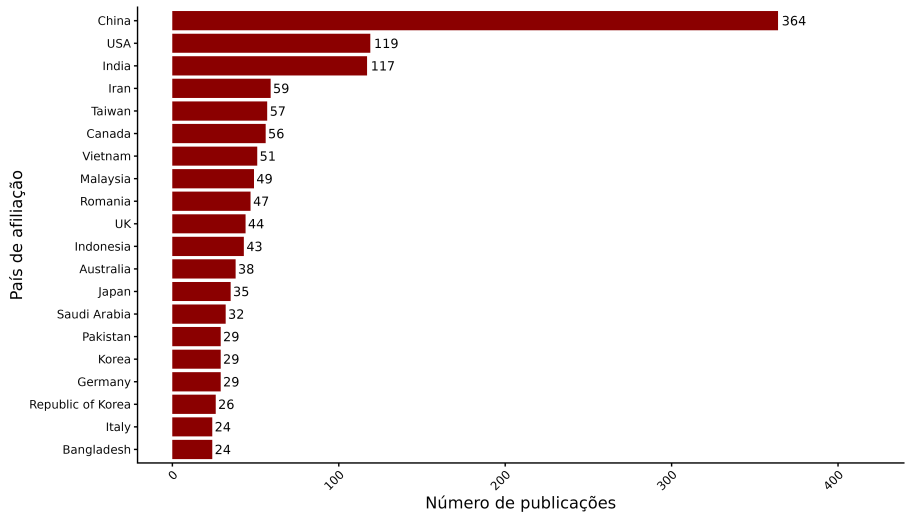
3.3.5 Distribuição geográfica

A China apresentou o maior número de publicações por afiliação (364), seguida por Estados Unidos (119) e Índia (117). Irã, Taiwan, Canadá e Vietnã também se destacaram (Figura 4). Brasil e outros países latino-americanos não figuraram entre os 20 primeiros. Esse resultado sugere sub-representação no corpus recuperado, mas não comprova ausência de estudos, pois depende da estratégia de busca, da cobertura das bases, do idioma e do método de contagem de afiliações.

3.3.6 Síntese dos artigos de maior prioridade

Os 13 artigos do Núcleo A foram publicados predominantemente entre 2018 e 2022 e apresentaram média de 283 citações na base consolidada. A Tabela 3 evidencia que o estrato não é composto apenas por previsão temporal, predominam o mapeamento de suscetibilidade, a classificação espacial e a integração com sensoriamento remoto. Essa composição explica a coexistência de métricas hidrológicas, como NSE e R^2, com métricas de classificação, como AUC, acurácia, sensibilidade e especificidade.

Figura 4 – Países com maior número de publicações segundo os metadados de afiliação. A unidade geográfica não deve ser confundida com o local de aplicação empírica do estudo.



Fonte: Elaborado pelos autores.

Tabela 3 – Síntese funcional dos 13 artigos do Núcleo A. Valores de desempenho não são comparados porque tarefas, dados, escalas e desenhos de validação diferem entre estudos.

Estudo	**Tarefa principal**	**Método**	**Contribuição científica central**
Xiang, Yan e Demir (2020)	Previsão chuva–vazão	LSTM *sequence-to-sequence*	Previsão em múltiplos passos e representação de dependências temporais.
Tyralis, Papacharalampous e Langousis (2019)	Revisão metodológica	Random Forest e variantes	Sistematização do uso de florestas aleatórias em recursos hídricos e importância de variáveis.
Hu *et al.* (2018)	Simulação chuva–vazão	LSTM	Aplicação de memória recorrente à dinâmica hidrológica e aos picos de vazão.
Janizadeh *et al.* (2019)	Suscetibilidade a enxurradas	ADT, FT, KLR, MLP e QDA	Comparação de classificadores sobre fatores geoambientais.
Dodangeh *et al.* (2020)	Suscetibilidade	GAM, MARS, BRT e reamostragem	Tratamento do desbalanceamento entre ocorrências e não ocorrências.
Rafiei-Sardooi *et al.* (2021)	Risco urbano	ML e TOPSIS	Integração entre perigo físico e vulnerabilidade socioeconômica.

continua na próxima página

Estudo	**Tarefa principal**	**Método**	**Contribuição científica central**
Zhao *et al.* (2019)	Suscetibilidade urbana	WELLSVM semissupervisionado	Aproveitamento de dados não rotulados em inventários incompletos.
Fang *et al.* (2021)	Suscetibilidade	LSTM	Uso de arquitetura recorrente em padrões espaciais de condicionantes.
Costache *et al.* (2020)	Suscetibilidade a enxurradas	KNN, AHP e análise multicritério	Integração entre ML, sensoriamento remoto, SIG e decisão multicritério.
Shahabi *et al.* (2020)	Detecção e suscetibilidade	Sentinel-1 e *ensemble* Bagging–KNN	Combinação de velocidade da Terra com classificadores *ensemble*.
Arora *et al.* (2021)	Suscetibilidade	ANFIS com GA, DE e PSO	Otimização metaheurística de modelos neurodifusos.
Wu *et al.* (2020)	Revisão de previsão	Previsão probabilística *ensemble*	Ênfase em incerteza, assimilação de dados e uso operacional.
Saha *et al.* (2021)	Suscetibilidade	Hyperpipes, SVR e *ensemble* HP–SVR	Combinação de algoritmos com perfis complementares de classificação.

Fonte: Elaborado pelos autores.

3.4 Discussão

3.4.1 Crescimento bibliométrico não equivale à maturidade operacional

O aumento de publicações revela forte mobilização científica, mas não demonstra, isoladamente, ganho em termos de generalização, robustez ou utilidade operacional. Parte do crescimento decorre da expansão dos dados de sensoriamento remoto, das reanálises meteorológicas, dos sensores de baixo custo e da infraestrutura computacional. O avanço mais relevante ocorre quando modelos são avaliados fora da amostra, em bacias, períodos e extremos não utilizados no treinamento. O sistema global analisado por Nearing *et al.* (2024) empregou validação espacial e temporal explícita e comparação com um sistema operacional de referência, oferecendo um padrão mais exigente do que o de divisões aleatórias de treino e teste.

3.4.2 A tarefa científica deve preceder a escolha do algoritmo

A principal fragilidade conceitual do corpus é o uso indiscriminado de "previsão de inundação" para tarefas distintas. A previsão hidrológica estima estados futuros e requer horizonte de antecedência, persistência, erro de pico, NSE, KGE, viés e calibração probabilística. Mapeamento de suscetibilidade estima a propensão espacial e costuma empregar AUC, sensibilidade, especificidade e acurácia. A detecção de inundação segmenta áreas afetadas em imagens e requer métricas como IoU e F1. Avaliação de risco combina perigo, exposição e vulnerabilidade, não podendo ser reduzida à acurácia de um classificador.

Consequentemente, valores elevados de AUC em um mapa de suscetibilidade não podem ser interpretados como evidência de capacidade de alerta em tempo real; da mesma forma, um bom NSE médio não garante reprodução dos extremos que interessam à defesa civil. Comparações futuras devem ser estratificadas por tarefa, escala, horizonte, fonte de dados e protocolo de validação.

3.4.3 Validação, dependência espacial e incerteza

Dados hidrológicos e geoespaciais apresentam autocorrelação temporal e espacial. Divisões aleatórias podem colocar observações muito semelhantes nos conjuntos de treino e teste, produzindo estimativas otimistas de desempenho. A validação bloqueada no espaço, no tempo e por evento, bem como testes em bacias não observadas, são necessários para avaliar a transferência real (ROBERTS *et al.*, 2017). Para aplicações operacionais, recomenda-se comparar a IA com referências simples e modelos físicos, reportar o desempenho por horizonte e por magnitude do evento, quantificar a incerteza e avaliar a calibração probabilística.

Modelos híbridos e guiados por conhecimento oferecem uma direção promissora, pois podem combinar flexibilidade estatística com restrições de balanço hídrico, de conectividade de drenagem e de coerência física (NEARING *et al.*, 2021). A interpretabilidade também deve ser tratada como requisito de segurança e de diagnóstico, e não apenas como recurso de visualização posterior.

3.4.4 Lacuna costeira, desigualdade de dados e aplicabilidade regional

A baixa representação latino-americana e a ausência de contextos costeiros brasileiros no Núcleo A são relevantes, mas precisam ser interpretadas com cautela. A própria expressão de busca privilegia termos genéricos e urbanos e não inclui explicitamente vocabulário de inundação costeira ou composta. Assim, parte da lacuna observada é substantiva e outra pode ser decorrente do desenho da busca.

Em municípios costeiros, modelos devem integrar precipitação, nível do rio, maré, sobreelevação meteorológica, ondas, impermeabilização e capacidade da drenagem. A aná-

lise isolada desses componentes pode subestimar eventos compostos (WAHL *et al.*, 2015). Para cidades médias e regiões com monitoramento limitado, a agenda mais promissora combina sensores locais, radar meteorológico, produtos de satélite, reanálises, modelos hidrodinâmicos simplificados e IA com transferência entre bacias. Dados abertos e protocolos comuns de validação são fundamentais para reduzir a desigualdade entre regiões bem monitoradas e áreas altamente vulneráveis.

3.4.5 Agenda de pesquisa

Os resultados sustentam cinco prioridades: (i) ampliar a estratégia de busca com vocabulário costeiro, composto e operacional; (ii) separar análises por tarefa científica; (iii) adotar validação espaço-temporal e por eventos extremos; (iv) combinar previsão pontual com incerteza, interpretabilidade e coerência física, e; (v) disponibilizar exportações, dicionários de palavras-chave, código de deduplicação e cálculo do escore. A tendência de adoção de Transformers e arquiteturas mais profundas é relevante. Entretanto, a maior complexidade dos modelos deve ser acompanhada por protocolos rigorosos de validação. Quando informações do período, local ou evento usado para avaliação também influenciam o treinamento, a potencial ocorrência de *data leakage* passa a ser aumentada, produzindo assim estimativas artificialmente elevadas de desempenho e pouca capacidade de generalização do modelo e detecção de novas enchentes.

3.5 Limitações

Algumas limitações condicionam a interpretação dos resultados. Primeiro, a triagem foi automatizada, sem avaliação manual por revisores, e depende de correspondência lexical de termos, que perde sinônimos e pode aceitar termos polissêmicos; a única verificação manual realizada foi a conferência, pela autora, dos 13 artigos do Núcleo A. Segundo, a cobertura da busca é parcial: na validação externa, apenas metade das referências internacionais de Dias *et al.* (2025) estava entre os registros recuperados, e a expressão de busca não abrangeu a totalidade de sinônimos de inundações pluviais, repentinas, costeiras e compostas. Terceiro, o escore é relativo ao corpus (reescala por mínimo e máximo), favorece artigos mais antigos pelo peso das citações, e o corte fixo do Núcleo A é sensível aos pesos e à composição do corpus, embora o ranking seja mais estável a variações moderadas. Quarto, o procedimento tem falhas de implementação documentadas: o mapeamento de colunas não reconheceu títulos do IEEE Xplore e campos da SciELO, de modo que o corpus provém, na prática, da Lens e da Scopus; 539 registros sem DOI foram descartados como se fossem duplicatas; a proveniência por base não foi preservada; e a exclusão por trecho de texto removeu 498 registros pertinentes (Seção 3.2.6). O total de 16.845 registros soma, ainda, exportações sobrepostas. Quinto, não foram realizadas análises de cocitação, de acoplamento bibliográfico nem de evolução temática. Sexto, a

exclusão de bases complementares como Web of Science restringe a captação de dinâmicas regionais, e o viés de indexação incompleta inviabiliza o uso pleno de dados de 2026. Por fim, as contagens por país refletem vínculos institucionais e não a localização empírica da bacia avaliada.

3.6 Conclusão

A literatura sobre IA aplicada a inundações expandiu-se rapidamente, com concentração de publicações após 2018 e crescimento de DL, LSTM, CNN e métodos *ensemble*. Random Forest, SVM e outras abordagens clássicas permanecem relevantes, especialmente no mapeamento espacial. China, Estados Unidos e Índia lideraram a produção por afiliação, enquanto a América Latina apareceu de forma limitada no recorte analisado.

A principal conclusão científica é que o campo não deve ser avaliado como um bloco homogêneo. Previsão temporal, detecção, suscetibilidade e risco associam-se a perguntas diferentes, utilizam métricas distintas e exigem protocolos específicos de validação. A próxima etapa de maturidade depende de generalização espaço-temporal, avaliação de extremos, quantificação de incerteza, integração com processos físicos e reprodutibilidade aberta. Para municípios costeiros do Sul do Brasil, estudos futuros devem considerar explicitamente inundações compostas e integrar observações locais, sensoriamento remoto, maré, chuva, drenagem e modelos híbridos orientados à decisão e ao alerta precoce.

3.7 Trabalhos relacionados

O uso de técnicas de inteligência artificial na previsão de eventos hidrológicos tem ganhado destaque nos últimos anos, diante das limitações dos modelos estatísticos tradicionais e da necessidade de soluções mais eficientes frente às mudanças climáticas. Entre essas técnicas, as Redes Neurais Artificiais (RNAs), especialmente as redes profundas como LSTM e as redes multicamadas do tipo perceptron, têm se mostrado promissoras na modelagem de dados ambientais com comportamento não linear.

Oliveira, Martins e Mendiondo (2013) aplicaram RNAs à previsão de vazões em rios urbanos, evidenciando ganhos expressivos de precisão em relação a métodos tradicionais baseados em regressão linear. Em estudo regional, Soares e Teive (2015) implementaram redes neurais para previsão de cheias no Rio Itajaí-Açu, em Santa Catarina, com resultados que demonstram a viabilidade dessas abordagens em cenários locais.

Mosavi, Ozturk e Chau (2018) realizaram uma análise comparativa abrangente entre diversos modelos de aprendizado de máquina aplicados à previsão de enchentes, concluindo que as redes neurais profundas superam algoritmos mais simples, especialmente em ambientes com alta variabilidade de dados e múltiplas variáveis de entrada.

No contexto urbano brasileiro, Valle (2021) utilizou RNAs para prever o número de ruas alagadas em Curitiba, obtendo coeficientes de determinação superiores a 0,95. Estrada (2021) aplicou redes neurais à previsão da demanda hídrica em Joinville (SC), destacando o potencial dessas técnicas para auxiliar no planejamento e na gestão de recursos hídricos.

Magro (2022) também demonstrou a eficiência das RNAs na previsão de profundidade de alagamentos em áreas urbanas da cidade de Lages (SC), com enfoque na construção de um sistema de alerta. Seus resultados indicaram que modelos com múltiplas saídas apresentaram melhor desempenho na redução de erros e aumento da confiabilidade preditiva.

Apesar dos avanços, ainda existem lacunas significativas. A maioria dos estudos concentra-se na previsão de variáveis hidrológicas específicas, como vazão ou nível de rios, mas poucos integram variáveis socioeconômicas e dados geoespaciais ao processo de modelagem. A integração desses elementos é essencial para avaliar não apenas o risco físico, mas também a vulnerabilidade social e a capacidade de resposta das comunidades afetadas.

Dessa forma, esta pesquisa se propõe a atuar nessa lacuna, integrando dados ambientais e sociais por meio de técnicas de inteligência artificial, com foco nas comunidades costeiras de Santa Catarina. A revisão da literatura indica que há um terreno fértil para inovação metodológica e aplicação prática, o que reforça a relevância científica e social da proposta.

Tabela 4 – Resumo dos principais trabalhos revisados

Autor(es)	**Contexto**	**Contribuição**
Oliveira, Martins e Mendiondo (2013)	Rios urbanos (Brasil)	Previsão de vazão com RNAs, mais precisas que modelos estatísticos tradicionais.
Soares e Teive (2015)	Bacia do Rio Itajaí-Açu	Aplicação regional de IA para previsão de cheias com bons resultados.
Mosavi, Ozturk e Chau (2018)	Revisão internacional	Avaliação de diversos algoritmos de IA, com destaque para redes neurais profundas.
Valle (2021)	Curitiba/PR	Previsão de alagamentos urbanos com RNAs, alta precisão preditiva.
Estrada (2021)	Joinville/SC	Demanda hídrica urbana com RNAs, reforçando aplicabilidade local.
Magro (2022)	Lages/SC	Alerta de alagamentos com RNAs multivariadas, foco em sistema preventivo.

Fonte: Elaborado pela autora.

CAPÍTULO

4

ANÁLISE EXPLORATÓRIA DOS DADOS

Capítulo a escrever: base de dados integrada, pré-processamento, definição de variáveis, arquitetura e treinamento dos modelos. Junção dos obj 1 e 2 com tabela de metadados de onde veio cada base assim como a especificação de cada uma (com foco).

CAPÍTULO

5

RESULTADOS

Capítulo a escrever: resultados, validação e comparação entre modelos.

CAPÍTULO

6

CONCLUSÃO

Este projeto busca oferecer uma solução tecnológica robusta, baseada em inteligência artificial, para a antecipação de enchentes em comunidades costeiras catarinenses. Ao integrar variáveis ambientais, hidrológicas e socioeconômicas, espera-se contribuir com conhecimento científico relevante e apoio técnico à tomada de decisões em políticas públicas de gestão de risco. A abordagem proposta é inovadora no contexto regional e se alinha aos desafios contemporâneos impostos pelas mudanças climáticas.

REFERÊNCIAS

ARIA, M.; CUCCURULLO, C. bibliometrix: An R-tool for comprehensive science mapping analysis. **Journal of Informetrics**, v. 11, n. 4, p. 959–975, 2017. Disponível em: <https://doi.org/10.1016/j.joi.2017.08.007>. Acesso em: 28 out. 2026. Citado nas páginas 20 e 22.

ARORA, A. *et al.* Optimization of state-of-the-art fuzzy-metaheuristic ANFIS-based machine learning models for flood susceptibility prediction mapping in the Middle Ganga Plain, India. **Science of the Total Environment**, v. 750, 2021. Art. 141565. Disponível em: <https://doi.org/10.1016/j.scitotenv.2020.141565>. Acesso em: 28 out. 2026. Citado na página 31.

BRASIL. **Atlas Irrigação: Uso da Água na Agricultura Irrigada**. Brasília: Agência Nacional de Águas e Saneamento Básico (ANA), 2021. Citado na página 10.

COSTACHE, R. *et al.* Flash-flood susceptibility assessment using multi-criteria decision making and machine learning supported by remote sensing and GIS techniques. **Remote Sensing**, v. 12, n. 1, 2020. Art. 106. Disponível em: <https://doi.org/10.3390/rs12010106>. Acesso em: 28 out. 2026. Citado na página 31.

DIAS, M. R. F. *et al.* State of the art techniques for flood prediction models – a systematic review. In: **17th Seminar on Power Electronics and Control (SEPOC)**. [s.n.], 2025. p. 1–7. Disponível em: <https://doi.org/10.1109/SEPOC67005.2025.11297645>. Acesso em: 28 out. 2026. Citado nas páginas 21, 24, 27 e 33.

DODANGEH, E. *et al.* Integrated machine learning methods with resampling algorithms for flood susceptibility prediction. **Science of the Total Environment**, v. 705, 2020. Art. 135983. Disponível em: <https://doi.org/10.1016/j.scitotenv.2019.135983>. Acesso em: 28 out. 2026. Citado na página 30.

ESTRADA, A. V. **Aplicação de redes neurais artificiais em modelos de previsão de demanda de água**. 2021. UDESC. Citado na página 35.

FANG, Z. *et al.* Predicting flood susceptibility using LSTM neural networks. **Journal of Hydrology**, v. 594, 2021. Art. 125734. Disponível em: <https://doi.org/10.1016/j.jhydrol.2020.125734>. Acesso em: 28 out. 2026. Citado na página 31.

HU, C. *et al.* Deep learning with a Long Short-Term Memory networks approach for rainfall–runoff simulation. **Water**, v. 10, n. 11, 2018. Art. 1543. Disponível em: <https://doi.org/10.3390/w10111543>. Acesso em: 28 out. 2026. Citado na página 30.

IPCC. **Climate Change 2021: The Physical Science Basis. Contribution of Working Group I to the Sixth Assessment Report of the Intergovernmental Panel on Climate Change**. Cambridge, UK; New York, NY, USA: Cambridge University Press, 2021. Citado na página 10.

IPCC. **Climate Change 2022: Impacts, Adaptation and Vulnerability**. Cambridge, UK: Cambridge University Press, 2022. Citado na página 20.

ISLAM, T. *et al.* A systematic review of urban flood susceptibility mapping: Remote sensing, machine learning, and other modeling approaches. **Remote Sensing**, v. 17, n. 3, 2025. Art. 524. Disponível em: <https://doi.org/10.3390/rs17030524>. Acesso em: 28 out. 2026. Nenhuma citação no texto.

JANIZADEH, S. *et al.* Prediction success of machine learning methods for flash flood susceptibility mapping in the Tafresh Watershed, Iran. **Sustainability**, v. 11, n. 19, 2019. Art. 5426. Disponível em: <https://doi.org/10.3390/su11195426>. Acesso em: 28 out. 2026. Citado na página 30.

KRATZERT, F. *et al.* Rainfall–runoff modelling using Long Short-Term Memory (LSTM) networks. **Hydrology and Earth System Sciences**, v. 22, p. 6005–6022, 2018. Disponível em: <https://doi.org/10.5194/hess-22-6005-2018>. Acesso em: 28 out. 2026. Citado na página 20.

MAGRO, R. B. **Utilização de técnicas de inteligência computacional para estimativa de vazões afluentes**. 2022. UFPel. Citado na página 35.

MOSAVI, A.; OZTURK, P.; CHAU, K.-W. Flood prediction using machine learning models: Literature review. **Water**, v. 10, n. 11, 2018. Art. 1536. Disponível em: <https://doi.org/10.3390/w10111536>. Acesso em: 28 out. 2026. Citado nas páginas 10, 14, 20, 26, 27, 34 e 35.

NEARING, G. *et al.* Global prediction of extreme floods in ungauged watersheds. **Nature**, v. 627, p. 559–563, 2024. Disponível em: <https://doi.org/10.1038/s41586-024-07145-1>. Acesso em: 28 out. 2026. Citado nas páginas 20 e 31.

NEARING, G. S. *et al.* What role does hydrological science play in the age of machine learning? **Water Resources Research**, v. 57, n. 3, 2021. Art. e2020WR028091. Disponível em: <https://doi.org/10.1029/2020WR028091>. Acesso em: 28 out. 2026. Citado nas páginas 20 e 32.

OLIVEIRA, R. A.; MARTINS, C. S.; MENDIONDO, E. M. Análise do uso de redes neurais artificiais na previsão de vazões em rios urbanos. In: **XX SBRH**. [S.l.: s.n.], 2013. Citado nas páginas 14, 34 e 35.

PAGE, M. J. *et al.* The PRISMA 2020 statement: An updated guideline for reporting systematic reviews. **BMJ**, v. 372, 2021. Art. n71. Disponível em: <https://doi.org/10.1136/bmj.n71>. Acesso em: 28 out. 2026. Citado nas páginas 20 e 21.

RAFIEI-SARDOOI, E. *et al.* Evaluating urban flood risk using hybrid method of TOPSIS and machine learning. **International Journal of Disaster Risk Reduction**, v. 66, 2021. Art. 102614. Disponível em: <https://doi.org/10.1016/j.ijdrr.2021.102614>. Acesso em: 28 out. 2026. Citado na página 30.

ROBERTS, D. R. *et al.* Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. **Ecography**, v. 40, n. 8, p. 913–929, 2017. Disponível em: <https://doi.org/10.1111/ecog.02881>. Acesso em: 28 out. 2026. Citado na página 32.

SAHA, A. *et al.* Flood susceptibility assessment using novel ensemble of Hyperpipes and support vector regression algorithms. **Water**, v. 13, n. 2, 2021. Art. 241. Disponível em: <https://doi.org/10.3390/w13020241>. Acesso em: 28 out. 2026. Citado na página 31.

SHAHABI, H. *et al.* Flood detection and susceptibility mapping using Sentinel-1 remote sensing data and a machine learning approach: Hybrid intelligence of bagging ensemble based on K-nearest neighbor classifier. **Remote Sensing**, v. 12, n. 2, 2020. Art. 266. Disponível em: <https://doi.org/10.3390/rs12020266>. Acesso em: 28 out. 2026. Citado na página 31.

SHEN, C. A transdisciplinary review of deep learning research and its relevance for water resources scientists. **Water Resources Research**, v. 54, n. 11, p. 8558–8593, 2018. Disponível em: <https://doi.org/10.1029/2018WR022643>. Acesso em: 28 out. 2026. Citado na página 20.

SOARES, D. G.; TEIVE, R. C. G. Previsão de cheias do Rio Itajaí-Açu utilizando redes neurais artificiais. In: **SIBGRAPI**. [S.l.: s.n.], 2015. Citado nas páginas 34 e 35.

TYRALIS, H.; PAPACHARALAMPOUS, G.; LANGOUSIS, A. A brief review of Random Forests for water scientists and practitioners and their recent history in water resources. **Water**, v. 11, n. 5, 2019. Art. 910. Disponível em: <https://doi.org/10.3390/w11050910>. Acesso em: 28 out. 2026. Citado na página 30.

VALLE, R. F. **Avaliação da utilização de redes neurais para previsão do risco de inundação em Curitiba/PR**. 2021. UTFPR. Citado na página 35.

WAHL, T. *et al.* Increasing risk of compound flooding from storm surge and rainfall for major US cities. **Nature Climate Change**, v. 5, p. 1093–1097, 2015. Disponível em: <https://doi.org/10.1038/nclimate2736>. Acesso em: 28 out. 2026. Citado nas páginas 20 e 33.

WU, W. *et al.* Ensemble flood forecasting: Current status and future opportunities. **WIREs Water**, v. 7, n. 3, 2020. Art. e1432. Disponível em: <https://doi.org/10.1002/wat2.1432>. Acesso em: 28 out. 2026. Citado na página 31.

XIANG, Z.; YAN, J.; DEMIR, I. A rainfall–runoff model with LSTM-based sequence-to-sequence learning. **Water Resources Research**, v. 56, n. 1, 2020. Art. e2019WR025326. Disponível em: <https://doi.org/10.1029/2019WR025326>. Acesso em: 28 out. 2026. Citado na página 30.

ZHANG, X. *et al.* Urban drought challenge to 2030 sustainable development goals. **Science of the Total Environment**, Elsevier, v. 693, p. 133455, 2019. Disponível em: <https://doi.org/10.1016/j.scitotenv.2019.07.273>. Acesso em: 28 out. 2026. Citado na página 10.

ZHAO, G. *et al.* Assessment of urban flood susceptibility using semi-supervised machine learning model. **Science of the Total Environment**, v. 659, p. 940–949, 2019. Disponível em: <https://doi.org/10.1016/j.scitotenv.2018.12.217>. Acesso em: 28 out. 2026. Citado na página 31.

Programa de Pós-Graduação em Computação – PPGC
Mestrado em Computação Aplicada - MCA

