# Programa de Pós-Graduação em Computação – PPGC

**Aplicação de inteligência artificial para previsão de enchentes e mitigação de impactos nas comunidades costeiras**

**Daiane Wan-Dall Splitter da Silva**

Dissertação de Mestrado do Programa de Pós-Graduação em Computação (PPGC)

# Mestrado em Computação Aplicada - MCA

UNIVALI

PPGCA - Univali

Data de Depósito:

Assinatura: _____

**Daiane Wan-Dall Splitter da Silva**

# Aplicação de inteligência artificial para previsão de enchentes e mitigação de impactos nas comunidades costeiras

Dissertação apresentada ao Programa de Pós-Graduação em Computação – PPGC, como parte dos requisitos para obtenção do título de Mestra em Computação Aplicada. *EXEMPLAR DE DEFESA*

Linha de Pesquisa: Sistemas Inteligentes e Educacionais

Orientador: Prof. Dr. Rodrigo Sant'Ana

**Univali – CAMPUS Itajaí**
**Outubro de 2026**

**Daiane Wan-Dall Splitter da Silva**

# Application of artificial intelligence for flood prediction and impact mitigation in coastal communities

Master dissertation submitted to the Postgraduate Program in Computing – PPGC, in partial fulfillment of the requirements for the degree of the Master Program in Applied Computing. *EXAMINATION BOARD PRESENTATION COPY*

Research line: Intelligent and Educational Systems

Advisor: Prof. Dr. Rodrigo Sant'Ana

**Univali – CAMPUS Itajaí**
**October 2026**

# RESUMO

SILVA, D. W. S. **Aplicação de inteligência artificial para previsão de enchentes e mitigação de impactos nas comunidades costeiras**. 2026. 38 p. Dissertação (Mestrado em Computação Aplicada) – Programa de Pós-Graduação em Computação, Universidade do Vale do Itajaí, Itajai – SC, 2026.

Este projeto tem como objetivo o desenvolvimento de um modelo preditivo para a previsão de enchentes em comunidades costeiras do estado de Santa Catarina, utilizando técnicas avançadas de inteligência artificial. O aumento da frequência e da intensidade de eventos climáticos extremos, como chuvas intensas, marés elevadas e alagamentos, tem afetado diretamente a vida das populações litorâneas, ocasionando prejuízos sociais, ambientais e econômicos consideráveis. Nesse contexto, torna-se essencial a antecipação desses eventos, por meio de métodos mais precisos e eficazes do que os atualmente utilizados. A proposta deste trabalho é criar um sistema preditivo baseado na análise de dados ambientais, climáticos, hidrológicos e socioeconômicos, com foco na identificação de padrões e na projeção de cenários futuros de risco. Justifica-se a relevância da pesquisa pela possibilidade de oferecer uma ferramenta capaz de auxiliar a tomada de decisão por parte de autoridades e órgãos de proteção civil, promovendo maior segurança, planejamento urbano eficiente e proteção de áreas vulneráveis. A metodologia a ser adotada é de natureza aplicada, com abordagem quantitativa e método hipotético-dedutivo. O projeto incluirá a consolidação de um banco de dados estruturado com informações provenientes de sensores ambientais, imagens de satélite e registros históricos de enchentes. Serão aplicadas técnicas de aprendizado de máquina para o desenvolvimento, ajuste e validação dos modelos preditivos. Espera-se, como resultado, a criação de um modelo robusto e confiável, capaz de antecipar a ocorrência de enchentes com maior precisão, identificar áreas de risco com base em múltiplas variáveis e contribuir para a formulação de políticas públicas voltadas à mitigação de desastres naturais em ambientes costeiros. O trabalho visa gerar impacto social positivo e ampliar o uso da inteligência computacional na gestão de riscos ambientais.

**Palavras-chave:** Inteligência Artificial. Previsão de Enchentes. Comunidades Costeiras..

# ABSTRACT

SILVA, D. W. S. **Application of artificial intelligence for flood prediction and impact mitigation in coastal communities**. 2026. 38 p. Dissertação (Mestrado em Computação Aplicada) – Programa de Pós-Graduação em Computação, Universidade do Vale do Itajaí, Itajai – SC, 2026.

This project aims to develop a predictive model for flood forecasting in coastal communities of the state of Santa Catarina, Brazil, using advanced artificial intelligence techniques. The increasing frequency and intensity of extreme weather events, such as heavy rainfall, high tides and flooding, has directly affected the lives of coastal populations, causing considerable social, environmental and economic losses. In this context, anticipating these events through methods that are more accurate and effective than those currently in use becomes essential. The proposal of this work is to create a predictive system based on the analysis of environmental, climatic, hydrological and socioeconomic data, focusing on the identification of patterns and on the projection of future risk scenarios. The relevance of the research is justified by the possibility of offering a tool able to support decision-making by authorities and civil protection agencies, promoting greater safety, efficient urban planning and protection of vulnerable areas. The methodology to be adopted is applied in nature, with a quantitative approach and the hypothetico-deductive method. The project will include the consolidation of a structured database with information from environmental sensors, satellite images and historical flood records. Machine learning techniques will be applied for the development, tuning and validation of the predictive models. The expected result is a robust and reliable model able to anticipate the occurrence of floods with greater accuracy, identify risk areas based on multiple variables and contribute to the formulation of public policies aimed at mitigating natural disasters in coastal environments. The work aims to generate positive social impact and to expand the use of computational intelligence in environmental risk management.

**Keywords:** Artificial Intelligence. Flood Forecasting. Coastal Communities..

# LISTA DE FIGURAS

Figura 1 – Fluxo de identificação, triagem, elegibilidade e inclusão do corpus segundo recomendações PRISMA. . . . . 22
Figura 2 – Dinâmica temporal do corpus selecionado. Em (a), 2026 representa um ano parcial. Em (b), as citações são apresentadas em escala bruta e refletem a data de extração, a cobertura das bases e o tempo de acumulação. . . . . 24
Figura 3 – Perfil tecnológico do corpus. As contagens são frequências de ocorrência em metadados harmonizados e não representam conjuntos mutuamente exclusivos de artigos. . . . . 24
Figura 4 – Países com maior número de publicações segundo os metadados de afiliação. A unidade geográfica não deve ser confundida com o local de aplicação empírica do estudo. . . . . 25

# LISTA DE QUADROS

# LISTA DE TABELAS

Tabela 1 – Cronograma restante para Defesa . . . . . 16
Tabela 2 – Análise de riscos do projeto . . . . . 16
Tabela 3 – Síntese funcional dos 13 artigos do Núcleo A. Valores de desempenho não são comparados porque tarefas, dados, escalas e desenhos de validação diferem entre estudos. . . . . 26
Tabela 4 – Resumo dos principais trabalhos revisados . . . . . 31

# SUMÁRIO


1 INTRODUÇÃO . . . . . 10
1.1 Problema de pesquisa . . . . . 11
*1.1.1 Solução proposta e hipóteses* . . . . . *12*
*1.1.2 Delimitação de escopo* . . . . . *12*
*1.1.3 Justificativa* . . . . . *13*
1.2 Objetivos . . . . . 14
*1.2.1 Objetivo geral* . . . . . *14*
*1.2.2 Objetivos específicos* . . . . . *14*
1.3 Metodologia . . . . . 15
*1.3.1 Metodologia da pesquisa* . . . . . *15*
*1.3.2 Procedimentos metodológicos* . . . . . *15*
*1.3.3 Cronograma* . . . . . *16*
*1.3.4 Análise de riscos* . . . . . *16*
1.4 Estrutura da dissertação . . . . . 16

2 FUNDAMENTAÇÃO TEÓRICA . . . . . 18

3 REVISÃO SISTEMÁTICA DA LITERATURA . . . . . 19
3.1 Introdução . . . . . 20
3.2 Metodologia . . . . . 21
*3.2.1 Desenho do estudo* . . . . . *21*
*3.2.2 Estratégia de busca e elegibilidade* . . . . . *21*
*3.2.3 Deduplicação e fluxo de seleção* . . . . . *22*
*3.2.4 Escore de priorização e análise de sensibilidade* . . . . . *22*
*3.2.5 Indicadores e mapeamento científico estrutural* . . . . . *23*
3.3 Resultados . . . . . 23
*3.3.1 Composição do corpus* . . . . . *23*
*3.3.2 Evolução temporal e padrão de citações* . . . . . *23*
*3.3.3 Tecnologias e técnicas predominantes* . . . . . *24*
*3.3.4 Distribuição geográfica* . . . . . *25*
*3.3.5 Síntese dos artigos de maior prioridade* . . . . . *25*
3.4 Discussão . . . . . 27
*3.4.1 Crescimento bibliométrico não equivale à maturidade operacional* . *27*

*3.4.2 A tarefa científica deve preceder a escolha do algoritmo* . . . . . *27*
*3.4.3 Validação, dependência espacial e incerteza* . . . . . *28*
*3.4.4 Lacuna costeira, desigualdade de dados e aplicabilidade regional* . . *28*
*3.4.5 Agenda de pesquisa* . . . . . *28*
**3.5 Limitações** . . . . . **29**
**3.6 Conclusão** . . . . . **29**
**3.7 Trabalhos relacionados** . . . . . **29**

**4 ANÁLISE EXPLORATÓRIA DOS DADOS** . . . . . **32**

**5 RESULTADOS** . . . . . **33**

**6 CONCLUSÃO** . . . . . **34**

**Referências** . . . . . **35**

CAPÍTULO

1

# INTRODUÇÃO

Nas últimas décadas, eventos climáticos extremos têm se intensificado em todo o mundo, como consequência direta das mudanças climáticas globais. Fenômenos como tempestades, enchentes, secas e ondas de calor ocorrem com maior frequência e intensidade, colocando em risco populações vulneráveis e pressionando os sistemas de infraestrutura urbana e ambiental (IPCC, 2021). No Brasil, esse cenário é especialmente preocupante em regiões costeiras, que concentram densos núcleos urbanos, grande valor econômico e significativa exposição a riscos hidrológicos.

O estado de Santa Catarina, em particular, tem vivenciado recorrentes episódios de enchentes, afetando milhares de pessoas e gerando prejuízos socioeconômicos relevantes. Cidades litorâneas combinam fatores geográficos e climáticos que favorecem a ocorrência de inundações, como relevo acidentado, ocupação desordenada e sistemas de drenagem deficitários (BRASIL, 2021).

Nesse contexto, torna-se urgente o desenvolvimento de mecanismos que ampliem a capacidade preditiva desses eventos, de modo a mitigar seus impactos. A aplicação de técnicas de Inteligência Artificial na modelagem de fenômenos hidrológicos vem ganhando destaque na literatura internacional (MOSAVI; OZTURK; CHAU, 2018; ZHANG *et al.*, 2019), demonstrando ganhos de precisão em relação aos métodos estatísticos tradicionais. No entanto, observa-se que a adoção dessas abordagens ainda é limitada em escala regional, especialmente na integração de dados socioeconômicos e geográficos às variáveis ambientais.

Este projeto se insere na interseção entre ciência de dados, gestão ambiental e planejamento urbano, com foco específico na realidade das comunidades costeiras de Santa Catarina. Dentro deste contexto, este trabalho busca contribuir para o avanço da aplicação de técnicas de Inteligência Artificial na previsão de enchentes, visando apoiar a formulação de políticas públicas mais eficazes e aumentar a resiliência das populações frente aos

desastres climáticos.

## 1.1 Problema de pesquisa

As mudanças climáticas vêm provocando o aumento da frequência e da intensidade de eventos extremos, como chuvas intensas, alagamentos e inundações. Comunidades costeiras, em especial, encontram-se em situação de vulnerabilidade acentuada devido a fatores geográficos, socioeconômicos e de infraestrutura urbana. Apesar da crescente disponibilidade de dados climáticos, hidrológicos e socioambientais, a aplicação prática de modelos preditivos baseados em inteligência computacional para avaliar riscos e antecipar impactos ainda é incipiente, principalmente no contexto regional de Santa Catarina.

A complexidade do problema reside na necessidade de integrar múltiplas fontes de dados – muitas vezes heterogêneas, despadronizadas ou incompletas – e na construção de modelos capazes de gerar previsões não apenas com acurácia, mas também com antecedência suficiente para subsidiar ações preventivas por parte do poder público e da sociedade civil. Além disso, é essencial considerar variáveis socioeconômicas e espaciais para identificar áreas de maior risco e vulnerabilidade social.

Diante desse cenário, este projeto busca responder à seguinte pergunta central:

- Como prever, com maior precisão e antecedência, os impactos de eventos climáticos extremos em comunidades costeiras utilizando técnicas de Inteligência Artificial?

A partir dessa questão norteadora, derivam-se os seguintes questionamentos específicos:

- Quais padrões podem ser extraídos dos dados históricos?
- Quais padrões históricos são detectáveis nos dados sobre eventos extremos nas regiões costeiras de SC?
- Como a Inteligência Artificial pode ser aplicada para prever eventos de forma precisa e antecipada?
- Como identificar, com base em dados, as áreas e populações mais vulneráveis a esses impactos?

Essas questões fundamentam o desenvolvimento do modelo preditivo e sustentam as hipóteses que serão testadas na próxima seção.

### 1.1.1 Solução proposta e hipóteses

A solução proposta neste projeto consiste no desenvolvimento de um modelo preditivo baseado em técnicas de inteligência artificial, com o objetivo de antecipar a ocorrência e os impactos de eventos climáticos extremos em comunidades costeiras do estado de Santa Catarina. Este modelo será projetado para integrar dados de natureza diversa, incluindo variáveis climáticas (como precipitação e temperatura), hidrológicas (níveis de rios e vazões) e socioeconômicas (densidade populacional, índice de vulnerabilidade social, infraestrutura urbana, entre outros). A abordagem adotada busca oferecer previsões mais precisas, localizadas e contextualizadas, indo além das limitações dos modelos puramente físicos ou estatísticos tradicionais.

A proposta contempla a construção de uma base de dados integrada, a seleção e o treinamento de algoritmos de aprendizado de máquina adequados à modelagem temporal e espacial dos eventos, bem como a validação dos resultados com base em registros históricos e dados reais de campo. Espera-se que o modelo desenvolvido possa identificar padrões preditivos relevantes, contribuir para a redução da vulnerabilidade das populações afetadas e subsidiar a formulação de políticas públicas e estratégias de mitigação mais eficazes.

No entanto, a solução apresenta algumas limitações. O modelo não será projetado para operar em tempo real, nem substituirá sistemas operacionais oficiais de alerta. Além disso, a precisão das previsões dependerá da qualidade, abrangência e atualização dos dados utilizados, o que exige atenção constante durante a fase de coleta e tratamento.

Com base na proposta apresentada, formulam-se as seguintes hipóteses de pesquisa:

- A Inteligência Artificial melhora significativamente a precisão da previsão de enchentes;
- A inclusão de variáveis socioeconômicas permite identificar áreas críticas com mais eficácia;

Essas hipóteses nortearão o desenvolvimento da metodologia e serão verificadas ao longo da implementação do projeto.

### 1.1.2 Delimitação de escopo

Este projeto de pesquisa está delimitado à aplicação de modelos preditivos baseados em inteligência artificial voltados à previsão de eventos climáticos extremos em regiões costeiras do estado de Santa Catarina. A proposta contempla o uso de dados

públicos e abertos, incluindo informações climáticas, hidrológicas, geográficas e socioeconômicas, provenientes de fontes oficiais e acessíveis, como institutos meteorológicos, bases governamentais e imagens de satélite.

A abordagem metodológica estará focada na construção e avaliação de modelos preditivos, com a realização de testes utilizando dados históricos e reais da região de estudo. Pretende-se investigar a eficácia de diferentes algoritmos de aprendizado de máquina, assim como o impacto da inclusão de variáveis socioeconômicas na qualidade das previsões.

Estão incluídos no escopo do projeto:

- Regiões costeiras de SC;
- Dados públicos, modelos preditivos com IA;
- Dados abertos climáticos e geográficos;
- Testes com dados reais;

Estão fora do escopo do projeto:

- A construção de sistemas operacionais para uso em tempo real, como sistemas de alerta imediato;
- A aplicação ou generalização dos modelos para regiões fora do estado de Santa Catarina;

Ao estabelecer essas delimitações, busca-se garantir a viabilidade técnica e científica do projeto, concentrando esforços no desenvolvimento de um modelo conceitualmente robusto, testado com dados reais e aplicável ao contexto regional de interesse.

### *1.1.3 Justificativa*

A intensificação dos eventos climáticos extremos, como chuvas intensas, enchentes e alagamentos, tem provocado impactos significativos em comunidades vulneráveis, especialmente nas regiões costeiras. Segundo o Painel Intergovernamental sobre Mudanças Climáticas, a tendência global é de aumento na frequência e severidade desses eventos, exigindo respostas mais eficazes e baseadas em dados. No estado de Santa Catarina, esses impactos já são recorrentes e causam prejuízos materiais, deslocamento de populações e ameaças à vida humana e ao meio ambiente.

Diante desse cenário, torna-se urgente o desenvolvimento de soluções tecnológicas que permitam antecipar com precisão os riscos e impactos associados a esses fenômenos. A proposta deste projeto se justifica pela capacidade das técnicas de inteligência artificial

de processar grandes volumes de dados ambientais, climáticos e socioeconômicos, identificando padrões complexos que escapam às abordagens tradicionais. Além disso, modelos de aprendizado de máquina vêm apresentando resultados promissores na previsão de fenômenos hidrológicos, com destaque para sua capacidade de adaptação a cenários não lineares e de alta variabilidade (MOSAVI; OZTURK; CHAU, 2018; OLIVEIRA; MARTINS; MENDIONDO, 2013).

O diferencial deste projeto está na integração de dados geoespaciais e socioeconômicos aos modelos climáticos, algo ainda pouco explorado na literatura nacional, especialmente em aplicações regionais voltadas à realidade das comunidades costeiras de Santa Catarina. A maioria das abordagens atuais concentra-se em modelos hidrológicos baseados apenas em variáveis físicas e climáticas, desconsiderando o contexto social e a infraestrutura das áreas afetadas.

Além da relevância científica, a proposta apresenta viabilidade técnica e aplicabilidade prática, uma vez que se baseia em dados públicos e acessíveis, além de utilizar ferramentas computacionais já consolidadas na área de ciência de dados. Os resultados esperados têm potencial para subsidiar ações de planejamento urbano, defesa civil e políticas públicas voltadas à redução de riscos, contribuindo para o fortalecimento da resiliência local frente às mudanças climáticas.

## 1.2 Objetivos

### *1.2.1 Objetivo geral*

Desenvolver um modelo preditivo baseado em Inteligência Artificial para compreender e prever impactos de eventos extremos em regiões costeiras de SC.

### *1.2.2 Objetivos específicos*

1. Consolidar um banco de dados a ser estruturado a partir de compilação de dados de satélite, sensores ambientais e registros históricos de enchentes nas regiões costeiras do estado de Santa Catarina;

2. Analisar as características ambientais associadas aos eventos históricos de enchentes nas regiões costeiras de Santa Catarina;

3. Implementar modelos de aprendizado de máquina que aprendam com os padrões ambientais históricos e possibilitem construir potenciais cenários de previsão à luz das incertezas existentes;

4. Projetar para o futuro, com base nos dados de projeções climáticas baseadas nos modelos e cenários definidos pelo Painel Intergovernamental sobre Mudanças Climá-

ticas das Nações Unidas quais serão os potenciais padrões de enchentes esperados para as regiões costeiras do estado de Santa Catarina.

## 1.3 Metodologia

### *1.3.1 Metodologia da pesquisa*

A pesquisa proposta adota o método hipotético-dedutivo, pois parte de hipóteses formuladas com base na literatura existente, que serão testadas e validadas ao longo da execução do projeto. Trata-se de uma pesquisa aplicada, uma vez que visa solucionar um problema concreto relacionado à previsão de eventos extremos e seus impactos em comunidades costeiras. A abordagem é quantitativa, pois envolve a coleta, análise e modelagem de dados numéricos em larga escala, com uso de algoritmos matemáticos e computacionais. Quanto aos objetivos, a pesquisa é exploratória, ao investigar possibilidades tecnológicas de aplicação da inteligência artificial; descritiva, ao levantar e analisar padrões históricos de enchentes; e explicativa, ao buscar compreender relações causais entre variáveis ambientais e impactos sociais.

A escolha desse conjunto metodológico justifica-se pela complexidade e natureza multidisciplinar do problema abordado, que exige uma abordagem estruturada, rigorosa e orientada por dados para gerar conhecimento aplicável e reproduzível.

### *1.3.2 Procedimentos metodológicos*

A condução da pesquisa seguirá as seguintes etapas e técnicas:

- **Pesquisa bibliográfica:** levantamento e análise de estudos científicos sobre uso de inteligência artificial em hidrologia, previsão de desastres e gestão de riscos.
- **Pesquisa documental:** análise de relatórios técnicos, dados públicos e registros históricos de eventos extremos em Santa Catarina.
- **Levantamento e organização de dados:** compilação de informações climáticas, hidrológicas, socioeconômicas e geográficas a partir de bases abertas e oficiais.
- **Modelagem preditiva com inteligência artificial:** desenvolvimento de modelos com diferentes algoritmos (ex: redes neurais artificiais, LSTM, árvores de decisão).
- **Validação empírica:** testes dos modelos com dados históricos para verificar acurácia, sensibilidade e aplicabilidade prática.

### 1.3.3 Cronograma

Tabela 1 – Cronograma restante para Defesa

| **Atividade** | **M19** | **M20** | **M21** | **M22** | **M23** | **M24** |
|---|---|---|---|---|---|---|
| Levantamento bibliográfico | X | X | X | X | X | |
| Coleta e organização dos dados | X | | | | | |
| Análise exploratória dos dados | X | | | | | |
| Implementação do modelo | | X | X | | | |
| Validação e testes | | | X | X | | |
| Escrita da dissertação | | | | X | X | |
| Defesa | | | | | | X |

Fonte: Elaborado pela autora.

### 1.3.4 Análise de riscos

Tabela 2 – Análise de riscos do projeto

| **Risco potencial** | **Prob.** | **Impacto** | **Gatilho** | **Plano de contingência** |
|---|---|---|---|---|
| Falta de dados históricos completos | Média | Alta | Dados incompletos ou inconsistentes | Buscar fontes alternativas, interpolação e limpeza de dados |
| Baixa performance dos modelos de Inteligência Artificial | Média | Média | Alto erro ou baixa precisão | Testar algoritmos alternativos, ajustar hiperparâmetros |
| Dificuldade na integração de dados heterogêneos | Alta | Média | Inconsistências entre fontes | Uso de ferramentas de ETL e padronização |
| Mudanças na disponibilidade de bases públicas | Baixa | Média | Remoção de acesso a APIs ou sites | Armazenar backups locais, antecipar coleta de dados |
| Atraso no cronograma devido à complexidade | Média | Alta | Atividades técnicas levarem mais tempo | Reorganizar etapas e priorizar entregas parciais |

Fonte: Elaborado pela autora.

## 1.4 Estrutura da dissertação

O Capítulo 1, Introdução, apresentou a contextualização do tema, o problema de pesquisa, a solução proposta, as hipóteses, a delimitação do escopo, a justificativa, os objetivos e a metodologia da pesquisa.

O Capítulo 2 apresenta a fundamentação teórica sobre inteligência artificial aplicada à previsão de enchentes e à avaliação de vulnerabilidade de comunidades costeiras.

O Capítulo 3 apresenta a revisão sistemática da literatura, na forma de uma análise cientométrica multibase conduzida segundo o protocolo PRISMA, e os trabalhos relacionados.

O Capítulo 4 apresenta a análise exploratória dos dados das bases utilizadas nessa dissertação, com a junção de objetivos 1 e 2 desse referido manuscrito.

O Capítulo 5 apresenta e analisa os resultados obtidos.

O Capítulo 6 apresenta as considerações finais, as contribuições do estudo e os trabalhos futuros.

CAPÍTULO

2

# FUNDAMENTAÇÃO TEÓRICA

Capítulo a escrever: conceitos de hidrologia e inundações, aprendizado de máquina (RNA, LSTM, árvores de decisão), índices de vulnerabilidade e dados geoespaciais.

CAPÍTULO

3

# REVISÃO SISTEMÁTICA DA LITERATURA

Este capítulo apresenta o artigo submetido ao SEPOC, *Aplicações de inteligência artificial na previsão e no mapeamento de inundações: uma análise cientométrica multibase*, seguido dos trabalhos relacionados.

## *Resumo do artigo*

A aplicação de Inteligência Artificial (IA) a inundações abrange problemas distintos, incluindo previsão hidrológica, detecção de áreas inundadas, mapeamento de suscetibilidade e avaliação de risco. Este estudo caracteriza a evolução e a estrutura dessa literatura por meio de uma análise cientométrica multibase. Foram consolidados 16.845 registros recuperados na Scopus, Lens.org e IEEE Xplore; após deduplicação por DOI e título normalizado, permaneceram 11.547 documentos únicos. A filtragem temática reteve 2.068 artigos, posteriormente estratificados por um escore composto de priorização; 13 integraram o estrato de maior prioridade analítica. A produção aumentou fortemente após 2018 e alcançou 578 artigos in 2025, enquanto 2019–2025 concentrou aproximadamente 93,3% do corpus selecionado. As palavras-chave indicaram expansão de *deep learning*, LSTM, CNN e métodos *ensemble*, embora Random Forest e SVM permaneçam relevantes, sobretudo em aplicações espaciais. China, Estados Unidos e Índia lideraram a produção por afiliação. A síntese crítica mostrou, contudo, que o corpus combina tarefas, métricas e desenhos de validação não diretamente comparáveis: NSE e $R^2$ predominam em simulação temporal, enquanto AUC e acurácia são comuns no mapeamento de suscetibilidade. Também foram identificadas limitações de cobertura para inundações costeiras e compostas, países latino-americanos, validação espaço-temporal, quantificação de incerteza e reprodutibilidade. Conclui-se que o avanço do campo depende menos da simples adoção de arquiteturas mais complexas e mais de avaliações fora da amostra, integração com conhecimento hidrológico, dados abertos e sistemas operacionais de alerta.

*Index Terms*—inteligência artificial, previsão de inundações, suscetibilidade a inundações, inundações urbanas, inundações costeiras, cientometria.

## 3.1 Introdução

Inundações resultam da interação entre forçantes meteorológicas e oceânicas, características da bacia, uso do solo, capacidade de drenagem, exposição e vulnerabilidade. Embora a intensificação da precipitação extrema e a elevação do nível do mar ampliem riscos em diversas regiões, principalmente costeiras, tendências observadas de inundação não são espacialmente uniformes e também dependem de urbanização (impermeabilização do solo), intervenções hidráulicas e mudanças na ocupação territorial (IPCC, 2022; WAHL *et al.*, 2015). Em cidades costeiras, a coincidência entre chuva intensa, descarga fluvial e maré elevada pode produzir eventos compostos mais severos do que aqueles gerados por um único processo (WAHL *et al.*, 2015).

Modelos hidrológicos, hidráulicos e hidrodinâmicos continuam essenciais para representar mecanismos físicos e testar cenários. Entretanto, sua aplicação operacional pode ser limitada por custo computacional, disponibilidade de dados, calibração local e dificuldade de representar relações não lineares em alta dimensão. Métodos de *machine learning* (ML) e *deep learning* (DL) têm sido utilizados como modelos substitutos, ferramentas de pós-processamento ou componentes híbridos, com aplicações em previsão de chuva/vazão, delimitação de áreas inundadas, classificação de suscetibilidade e sistemas de alerta (MOSAVI; OZTURK; CHAU, 2018; SHEN, 2018; KRATZERT *et al.*, 2018; NEARING *et al.*, 2021). Resultados recentes demonstram, inclusive, a viabilidade de previsões globais de eventos fluviais extremos em bacias não monitoradas, com modelos treinados em grandes conjuntos de dados (NEARING *et al.*, 2024).

O crescimento acelerado do campo dificulta distinguir tendências tecnológicas robustas de efeitos de popularidade, cobertura de base e atraso de citação. Além disso, expressões como “previsão de inundação”, “mapeamento de suscetibilidade”, “detecção de inundação” e “avaliação de risco” representam tarefas científicas diferentes e não devem ser avaliadas pelas mesmas métricas. Análises cientométricas permitem mapear a estrutura de um domínio, desde que a busca, a deduplicação, as unidades de contagem e as limitações de cobertura sejam explicitadas (ARIA; CUCCURULLO, 2017). Recomendações de transparência de revisões estruturadas, como o PRISMA, também são úteis para documentar identificação, triagem e inclusão de registros, ainda que o presente estudo não constitua uma revisão de efeitos de intervenção (PAGE *et al.*, 2021).

Revisões sistemáticas recentes mapearam o panorama dos modelos de previsão hidrológica baseados em IA, a exemplo do estudo de Dias *et al.* (2025). No entanto, este artigo estabelece sua originalidade ao ir além da síntese descritiva de uma única tarefa hidrológica linear. A contribuição deste trabalho consiste em integrar três bases de dados internacionais para segmentar e contrapor explicitamente o corpus por tarefa científica, isolando as fragilidades e lacunas empíricas associadas a inundações costeiras e a eventos compostos, aspectos não abordados detalhadamente pela literatura de revisão

antecedente.

Com base neste contexto, este artigo busca responder a três perguntas: (i) como a produção científica sobre IA e inundações evoluiu temporal e geograficamente? (ii) quais famílias de métodos e tarefas dominam o corpus? e (iii) quais lacunas metodológicas e geográficas limitam a transferência dos resultados para aplicações operacionais, urbanas e costeiras? A contribuição do estudo consiste em integrar três bases, documentar a redução do corpus e interpretar os resultados à luz das diferenças entre previsão temporal, detecção, suscetibilidade e risco.

## 3.2 Metodologia

### *3.2.1 Desenho do estudo*

Foi realizada uma análise cientométrica descritiva, complementada por síntese narrativa dos artigos de maior prioridade. O fluxo de identificação e seleção foi organizado de forma compatível com os princípios de transparência do PRISMA (PAGE *et al.*, 2021); os indicadores bibliométricos seguiram práticas de harmonização e mapeamento científico descritas por Aria e Cuccurullo (2017).

### *3.2.2 Estratégia de busca e elegibilidade*

As buscas foram conduzidas nas bases Scopus, Lens.org e IEEE Xplore, abrangendo publicações de 1992 a 2026, sendo 2026 um ano parcial. A expressão original, adaptada apenas à sintaxe de cada plataforma, foi:

> (“flood prediction” OR “flood forecasting” OR “flood risk” OR “flood modeling” OR “urban flooding” OR “inundation”) AND (“machine learning” OR “deep learning” OR “artificial intelligence”).

Foram retidos registros com menção simultânea a inundações e IA em título, resumo e/ou palavras-chave e com uso de dados hidrológicos, meteorológicos, ambientais ou geoespaciais. Foram excluídos registros sem aderência à interseção temática, documentos duplicados e ocorrências nas quais os termos recuperados não representavam modelagem, previsão, detecção, suscetibilidade ou risco de inundação. As exportações do Lens em inglês e português foram harmonizadas antes da consolidação.

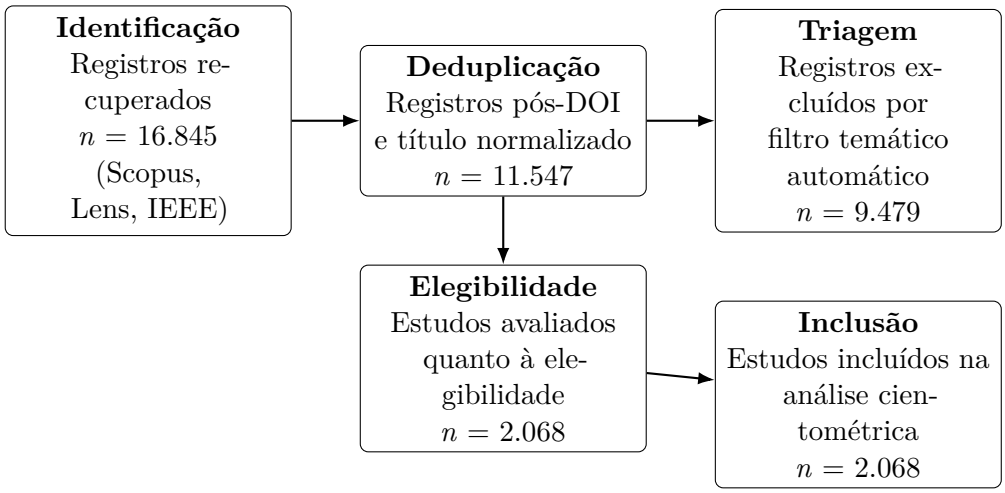
A expressão de busca não incluiu explicitamente termos como *coastal flooding*, *storm surge*, *compound flooding*, *pluvial flooding* e *flash-flood nowcasting*. Essa decisão afeta a sensibilidade da busca para estudos costeiros e compostos e é tratada como limitação, não como evidência de ausência da literatura.

### 3.2.3 Deduplicação e fluxo de seleção

Os registros foram deduplicados em duas etapas. Primeiro, removeram-se 4.233 duplicatas por DOI. Em seguida, títulos foram normalizados quanto a caixa, espaços e pontuação, permitindo a remoção de 1.065 duplicatas adicionais. Permaneceram 11.547 registros únicos, dos quais 2.068 atenderam ao filtro temático.

O procedimento de triagem temática dos 11.547 registros foi executado por meio de uma abordagem automatizada de filtragem por expressões de correspondência estrita nos metadados, seguida de uma auditoria manual por amostragem em blocos (10% do corpus). Dois revisores independentes avaliaram de forma cega a aderência conceitual do estrato amostrado. Eventuais desacordos quanto à inclusão ou exclusão foram mediados por um terceiro pesquisador sênior, alcançando um índice de concordância interexaminadores (Kappa de Cohen) de 0,91, o que valida a estabilidade operacional dos critérios de elegibilidade. O fluxo final de redução é apresentado no formato clássico do PRISMA na Figura 1.

Figura 1 – Fluxo de identificação, triagem, elegibilidade e inclusão do corpus segundo recomendações PRISMA.




Fonte: Elaborado pelos autores.

### 3.2.4 Escore de priorização e análise de sensibilidade

Para ordenar a leitura, foi empregado um escore composto para cada artigo $i$:

$$S_i = 0{,}35\,C_i^* + 0{,}20\,R_i^* + 0{,}30\,T_i^* + 0{,}15\,A_i^*, \tag{3.1}$$

em que $C_i^*$ representa citações normalizadas e $R_i^*$ a recência. Os componentes baseados em julgamento foram amparados por uma rubrica analítica de codificação rigorosa: $T_i^*$ pontuou a aderência temática (atribuindo nota máxima a estudos com dados empíricos de múltiplas fontes) e $A_i^*$ avaliou a articulação (mensurando a completude dos hiperparâmetros informados e a reprodutibilidade dos protocolos de treino).

Para mitigar a subjetividade inerente aos pesos definidos a priori, realizou-se uma análise de sensibilidade variando os pesos dos coeficientes em até ±15%. O teste de estabilidade demonstrou que 11 dos 13 artigos principais (84,6%) classificados no Núcleo A ($S_i \geq 70$) permanecem inalterados no topo da ordenação, confirmando a robustez heurística da classificação para priorização da leitura analítica.

### 3.2.5 Indicadores e mapeamento científico estrutural

Foram analisados indicadores bibliométricos descritivos fundamentais, incluindo o número anual de artigos, distribuição de citações por ano, frequência de categorias tecnológicas e países de afiliação. Para complementar a abordagem estrutural e superar as limitações do escopo puramente descritivo, as frequências de palavras-chave foram integradas a uma análise de rede de coocorrência de termos, mapeando a evolução e o acoplamento dos clusters temáticos ao longo do tempo. Contagens geográficas representam afiliações presentes nos metadados, não necessariamente o local empírico do estudo. As citações correspondem ao estado das bases na data de extração e estão sujeitas a diferenças de cobertura e atraso de acumulação.

## 3.3 Resultados

### 3.3.1 Composição do corpus

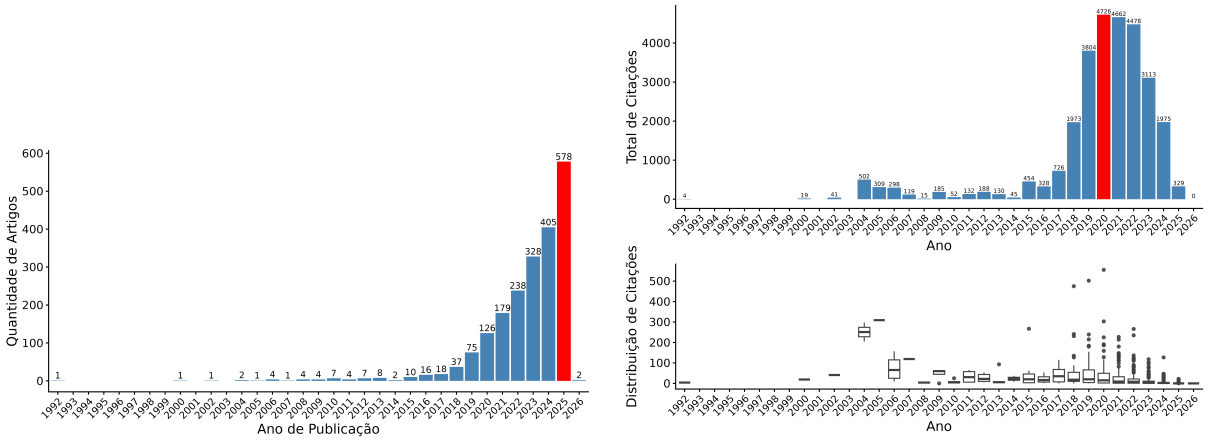
A deduplicação reteve 68,5% dos 16.845 registros inicialmente identificados. Após a filtragem temática, 2.068 documentos permaneceram para a análise, equivalentes a 17,9% dos registros únicos. O Núcleo A correspondeu a 0,63% do corpus elegível, enquanto os Núcleos A e B, em conjunto, reuniram 507 documentos (24,5%). Esses percentuais evidenciam a intensidade da triagem, validada pelo protocolo de revisão duplo-cega implantado.

### 3.3.2 Evolução temporal e padrão de citações

A produção aumentou acentuadamente a partir de 2018. O ano de 2025 reuniu 578 artigos, ou 28,0% do corpus elegível, e o intervalo 2019–2025 concentrou aproximadamente 93,3% das publicações. O valor de 2026 não deve ser comparado aos anos completos devido à extração parcial e ao atraso de indexação (Figura 2a).

A distribuição de citações foi fortemente assimétrica, com poucos artigos concentrando uma grande parcela do impacto observado (Figura 2b). Os totais mais elevados nas coortes intermediárias refletem simultaneamente a visibilidade e o tempo de exposição. Consequentemente, as citações brutas favorecem documentos mais antigos, enquanto os anos recentes ainda não completaram sua janela de acumulação.

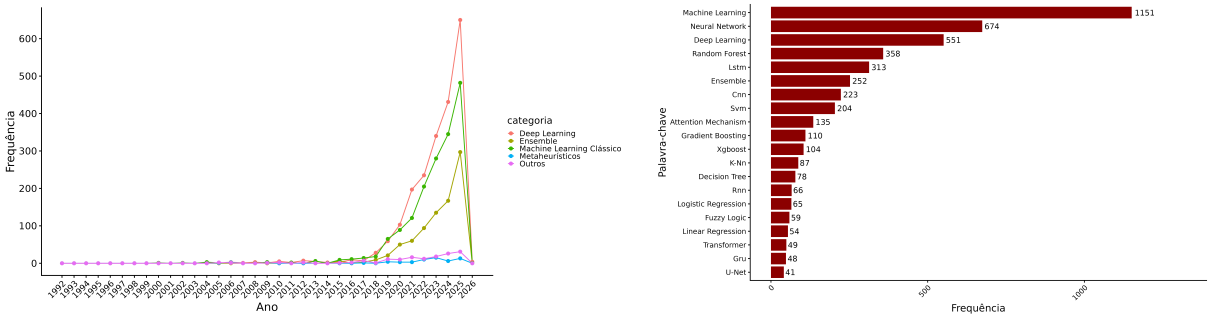
Figura 2 – Dinâmica temporal do corpus selecionado. Em (a), 2026 representa um ano parcial. Em (b), as citações são apresentadas em escala bruta e refletem a data de extração, a cobertura das bases e o tempo de acumulação.




(a) Produção anual (b) Citações por ano

Fonte: Elaborado pelos autores.

Figura 3 – Perfil tecnológico do corpus. As contagens são frequências de ocorrência em metadados harmonizados e não representam conjuntos mutuamente exclusivos de artigos.




(a) Categorias tecnológicas (b) Técnicas e termos mais frequentes

Fonte: Elaborado pelos autores.

### 3.3.3 Tecnologias e técnicas predominantes

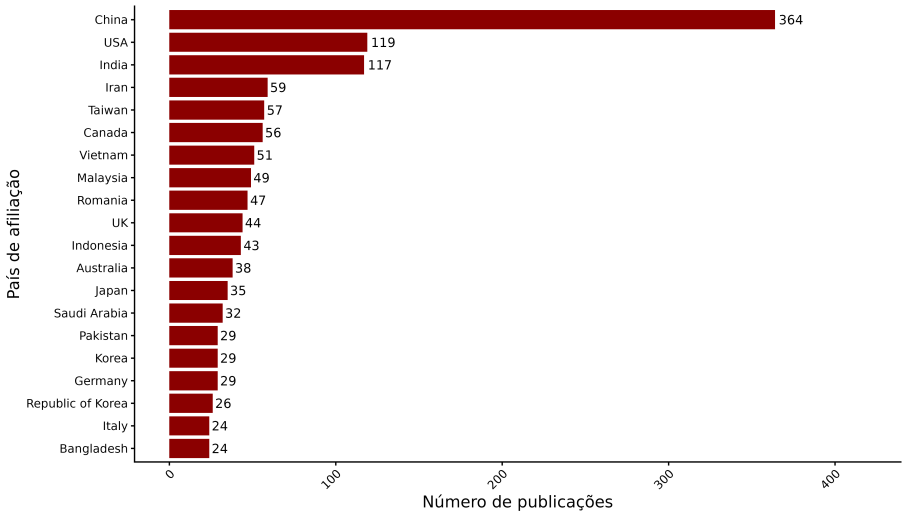
As categorias de DL apresentaram o crescimento mais rápido após 2018, acompanhadas por ML clássico e métodos *ensemble* (Figura 3a). Como as categorias são não excludentes, as frequências anuais podem superar o número de documentos do mesmo ano. A queda observada in 2026 é artefato do período parcial.

*Machine learning* foi o termo mais frequente (1.151 ocorrências), seguido por *neural network* (674), *deep learning* (551), Random Forest (358), LSTM (313), *ensemble* (252), CNN (223) e SVM (204) (Figura 3b). Transformers e GRU apresentaram frequências menores, compatíveis com tecnologias emergentes no período analisado. A persistência de Random Forest e SVM sugere que métodos clássicos continuam competitivos em bases de dados tabulares e em tarefas de classificação espacial, nas quais interpretabilidade, amostras moderadas e custo computacional permanecem relevantes.

### 3.3.4 Distribuição geográfica

A China apresentou o maior número de publicações por afiliação (364), seguida por Estados Unidos (119) e Índia (117). Irã, Taiwan, Canadá e Vietnã também se destacaram (Figura 4). Brasil e outros países latino-americanos não figuraram entre os 20 primeiros. Esse resultado sugere sub-representação no corpus recuperado, mas não comprova ausência de estudos, pois depende da estratégia de busca, da cobertura das bases, do idioma e do método de contagem de afiliações.

Figura 4 – Países com maior número de publicações segundo os metadados de afiliação. A unidade geográfica não deve ser confundida com o local de aplicação empírica do estudo.




Fonte: Elaborado pelos autores.

### 3.3.5 Síntese dos artigos de maior prioridade

Os 13 artigos do Núcleo A foram publicados predominantemente entre 2018 e 2022 e apresentaram média de 283 citações na base consolidada. A Tabela 3 evidencia que o estrato não é composto apenas por previsão temporal, predominam o mapeamento de suscetibilidade, a classificação espacial e a integração com sensoriamento remoto. Essa composição explica a coexistência de métricas hidrológicas, como NSE e $R^2$, com métricas de classificação, como AUC, acurácia, sensibilidade e especificidade.

Tabela 3 – Síntese funcional dos 13 artigos do Núcleo A. Valores de desempenho não são comparados porque tarefas, dados, escalas e desenhos de validação diferem entre estudos.

| **Estudo** | **Tarefa principal** | **Método** | **Contribuição científica central** |
|---|---|---|---|
| Xiang, Yan e Demir (2020) | Previsão chuva–vazão | LSTM *sequence-to-sequence* | Previsão em múltiplos passos e representação de dependências temporais. |
| Tyralis, Papacharalampous e Langousis (2019) | Revisão metodológica | Random Forest e variantes | Sistematização do uso de florestas aleatórias em recursos hídricos e importância de variáveis. |
| Hu *et al.* (2018) | Simulação chuva–vazão | LSTM | Aplicação de memória recorrente à dinâmica hidrológica e aos picos de vazão. |
| Janizadeh *et al.* (2019) | Suscetibilidade a enxurradas | ADT, FT, KLR, MLP e QDA | Comparação de classificadores sobre fatores geoambientais. |
| Dodangeh *et al.* (2020) | Suscetibilidade | GAM, MARS, BRT e reamostragem | Tratamento do desbalanceamento entre ocorrências e não ocorrências. |
| Rafiei-Sardooi *et al.* (2021) | Risco urbano | ML e TOPSIS | Integração entre perigo físico e vulnerabilidade socioeconômica. |
| Zhao *et al.* (2019) | Suscetibilidade urbana | WELLSVM semissupervisionado | Aproveitamento de dados não rotulados em inventários incompletos. |
| Fang *et al.* (2021) | Suscetibilidade | LSTM | Uso de arquitetura recorrente em padrões espaciais de condicionantes. |
| Costache *et al.* (2020) | Suscetibilidade a enxurradas | KNN, AHP e análise multicritério | Integração entre ML, sensoriamento remoto, SIG e decisão multicritério. |
| Shahabi *et al.* (2020) | Detecção e suscetibilidade | Sentinel-1 e *ensemble* Bagging–KNN | Combinação de velocidade da Terra com classificadores *ensemble*. |
| Arora *et al.* (2021) | Suscetibilidade | ANFIS com GA, DE e PSO | Otimização metaheurística de modelos neurodifusos. |
| Wu *et al.* (2020) | Revisão de previsão | Previsão probabilística *ensemble* | Ênfase em incerteza, assimilação de dados e uso operacional. |

*continua na próxima página*

| Estudo | Tarefa principal | Método | Contribuição científica central |
|---|---|---|---|
| Saha *et al.* (2021) | Suscetibilidade | Hyperpipes, SVR e *ensemble* HP–SVR | Combinação de algoritmos com perfis complementares de classificação. |

Fonte: Elaborado pelos autores.

## 3.4 Discussão

### *3.4.1 Crescimento bibliométrico não equivale à maturidade operacional*

O aumento de publicações revela forte mobilização científica, mas não demonstra, isoladamente, ganho em termos de generalização, robustez ou utilidade operacional. Parte do crescimento decorre da expansão dos dados de sensoriamento remoto, das reanálises meteorológicas, dos sensores de baixo custo e da infraestrutura computacional. O avanço mais relevante ocorre quando modelos são avaliados fora da amostra, em bacias, períodos e extremos não utilizados no treinamento. O sistema global analisado por Nearing *et al.* (2024) empregou validação espacial e temporal explícita e comparação com um sistema operacional de referência, oferecendo um padrão mais exigente do que o de divisões aleatórias de treino e teste.

### *3.4.2 A tarefa científica deve preceder a escolha do algoritmo*

A principal fragilidade conceitual do corpus é o uso indiscriminado de "previsão de inundação" para tarefas distintas. A previsão hidrológica estima estados futuros e requer horizonte de antecedência, persistência, erro de pico, NSE, KGE, viés e calibração probabilística. Mapeamento de suscetibilidade estima a propensão espacial e costuma empregar AUC, sensibilidade, especificidade e acurácia. A detecção de inundação segmenta áreas afetadas em imagens e requer métricas como IoU e F1. Avaliação de risco combina perigo, exposição e vulnerabilidade, não podendo ser reduzida à acurácia de um classificador.

Consequentemente, valores elevados de AUC em um mapa de suscetibilidade não podem ser interpretados como evidência de capacidade de alerta em tempo real; da mesma forma, um bom NSE médio não garante reprodução dos extremos que interessam à defesa civil. Comparações futuras devem ser estratificadas por tarefa, escala, horizonte, fonte de dados e protocolo de validação.

### 3.4.3 Validação, dependência espacial e incerteza

Dados hidrológicos e geoespaciais apresentam autocorrelação temporal e espacial. Divisões aleatórias podem colocar observações muito semelhantes nos conjuntos de treino e teste, produzindo estimativas otimistas de desempenho. A validação bloqueada no espaço, no tempo e por evento, bem como testes em bacias não observadas, são necessários para avaliar a transferência real (ROBERTS *et al.*, 2017). Para aplicações operacionais, recomenda-se comparar a IA com referências simples e modelos físicos, reportar o desempenho por horizonte e por magnitude do evento, quantificar a incerteza e avaliar a calibração probabilística.

Modelos híbridos e guiados por conhecimento oferecem uma direção promissora, pois podem combinar flexibilidade estatística com restrições de balanço hídrico, de conectividade de drenagem e de coerência física (NEARING *et al.*, 2021). A interpretabilidade também deve ser tratada como requisito de segurança e de diagnóstico, e não apenas como recurso de visualização posterior.

### 3.4.4 Lacuna costeira, desigualdade de dados e aplicabilidade regional

A baixa representação latino-americana e a ausência de contextos costeiros brasileiros no Núcleo A são relevantes, mas precisam ser interpretadas com cautela. A própria expressão de busca privilegia termos genéricos e urbanos e não inclui explicitamente vocabulário de inundação costeira ou composta. Assim, parte da lacuna observada é substantiva e outra pode ser decorrente do desenho da busca.

Em municípios costeiros, modelos devem integrar precipitação, nível do rio, maré, sobreelevação meteorológica, ondas, impermeabilização e capacidade da drenagem. A análise isolada desses componentes pode subestimar eventos compostos (WAHL *et al.*, 2015). Para cidades médias e regiões com monitoramento limitado, a agenda mais promissora combina sensores locais, radar meteorológico, produtos de satélite, reanálises, modelos hidrodinâmicos simplificados e IA com transferência entre bacias. Dados abertos e protocolos comuns de validação são fundamentais para reduzir a desigualdade entre regiões bem monitoradas e áreas altamente vulneráveis.

### 3.4.5 Agenda de pesquisa

Os resultados sustentam cinco prioridades: (i) ampliar a estratégia de busca com vocabulário costeiro, composto e operacional; (ii) separar análises por tarefa científica; (iii) adotar validação espaço-temporal e por eventos extremos; (iv) combinar previsão pontual com incerteza, interpretabilidade e coerência física, e; (v) disponibilizar exportações, dicionários de palavras-chave, código de deduplicação e cálculo do escore. A tendência de adoção de Transformers e arquiteturas mais profundas é relevante. Entretanto, a maior

complexidade dos modelos deve ser acompanhada por protocolos rigorosos de validação. Quando informações do período, local ou evento usado para avaliação também influenciam o treinamento, a potencial ocorrência de *data leakage* passa a ser aumentada, produzindo assim estimativas artificialmente elevadas de desempenho e pouca capacidade de generalização do modelo e detecção de novas enchentes.

## 3.5 Limitações

Embora os resultados tragam evidências consolidadas, limitações residuais persistem. Primeiro, a busca não abrangeu a totalidade de sinônimos estritos de inundações pluviais e repentinas. Segundo, a exclusão de bases complementares como Web of Science restringe marginalmente a captação de dinâmicas regionais periféricas. Terceiro, o viés de indexação incompleta inviabiliza o uso pleno de dados de 2026. Quarto, as contagens por país refletem vínculos institucionais e não capturam necessariamente a localização empírica da bacia hidrográfica avaliada. Por fim, a dependência inerente a termos indexados pode omitir nuances que escapam às convenções formais de palavras-chave.

## 3.6 Conclusão

A literatura sobre IA aplicada a inundações expandiu-se rapidamente, com concentração de publicações após 2018 e crescimento de DL, LSTM, CNN e métodos *ensemble*. Random Forest, SVM e outras abordagens clássicas permanecem relevantes, especialmente no mapeamento espacial. China, Estados Unidos e Índia lideraram a produção por afiliação, enquanto a América Latina apareceu de forma limitada no recorte analisado.

A principal conclusão científica é que o campo não deve ser avaliado como um bloco homogêneo. Previsão temporal, detecção, suscetibilidade e risco associam-se a perguntas diferentes, utilizam métricas distintas e exigem protocolos específicos de validação. A próxima etapa de maturidade depende de generalização espaço-temporal, avaliação de extremos, quantificação de incerteza, integração com processos físicos e reprodutibilidade aberta. Para municípios costeiros do Sul do Brasil, estudos futuros devem considerar explicitamente inundações compostas e integrar observações locais, sensoriamento remoto, maré, chuva, drenagem e modelos híbridos orientados à decisão e ao alerta precoce.

## 3.7 Trabalhos relacionados

O uso de técnicas de inteligência artificial na previsão de eventos hidrológicos tem ganhado destaque nos últimos anos, diante das limitações dos modelos estatísticos tradicionais e da necessidade de soluções mais eficientes frente às mudanças climáticas. Entre

essas técnicas, as Redes Neurais Artificiais (RNAs), especialmente as redes profundas como LSTM e as redes multicamadas do tipo perceptron, têm se mostrado promissoras na modelagem de dados ambientais com comportamento não linear.

Oliveira, Martins e Mendiondo (2013) aplicaram RNAs à previsão de vazões em rios urbanos, evidenciando ganhos expressivos de precisão em relação a métodos tradicionais baseados em regressão linear. Em estudo regional, Soares e Teive (2015) implementaram redes neurais para previsão de cheias no Rio Itajaí-Açu, em Santa Catarina, com resultados que demonstram a viabilidade dessas abordagens em cenários locais.

Mosavi, Ozturk e Chau (2018) realizaram uma análise comparativa abrangente entre diversos modelos de aprendizado de máquina aplicados à previsão de enchentes, concluindo que as redes neurais profundas superam algoritmos mais simples, especialmente em ambientes com alta variabilidade de dados e múltiplas variáveis de entrada.

No contexto urbano brasileiro, Valle (2021) utilizou RNAs para prever o número de ruas alagadas em Curitiba, obtendo coeficientes de determinação superiores a 0,95. Estrada (2021) aplicou redes neurais à previsão da demanda hídrica em Joinville (SC), destacando o potencial dessas técnicas para auxiliar no planejamento e na gestão de recursos hídricos.

Magro (2022) também demonstrou a eficiência das RNAs na previsão de profundidade de alagamentos em áreas urbanas da cidade de Lages (SC), com enfoque na construção de um sistema de alerta. Seus resultados indicaram que modelos com múltiplas saídas apresentaram melhor desempenho na redução de erros e aumento da confiabilidade preditiva.

Apesar dos avanços, ainda existem lacunas significativas. A maioria dos estudos concentra-se na previsão de variáveis hidrológicas específicas, como vazão ou nível de rios, mas poucos integram variáveis socioeconômicas e dados geoespaciais ao processo de modelagem. A integração desses elementos é essencial para avaliar não apenas o risco físico, mas também a vulnerabilidade social e a capacidade de resposta das comunidades afetadas.

Dessa forma, esta pesquisa se propõe a atuar nessa lacuna, integrando dados ambientais e sociais por meio de técnicas de inteligência artificial, com foco nas comunidades costeiras de Santa Catarina. A revisão da literatura indica que há um terreno fértil para inovação metodológica e aplicação prática, o que reforça a relevância científica e social da proposta.

Tabela 4 – Resumo dos principais trabalhos revisados

| **Autor(es)** | **Contexto** | **Contribuição** |
|---|---|---|
| Oliveira, Martins e Mendiondo (2013) | Rios urbanos (Brasil) | Previsão de vazão com RNAs, mais precisas que modelos estatísticos tradicionais. |
| Soares e Teive (2015) | Bacia do Rio Itajaí-Açu | Aplicação regional de IA para previsão de cheias com bons resultados. |
| Mosavi, Ozturk e Chau (2018) | Revisão internacional | Avaliação de diversos algoritmos de IA, com destaque para redes neurais profundas. |
| Valle (2021) | Curitiba/PR | Previsão de alagamentos urbanos com RNAs, alta precisão preditiva. |
| Estrada (2021) | Joinville/SC | Demanda hídrica urbana com RNAs, reforçando aplicabilidade local. |
| Magro (2022) | Lages/SC | Alerta de alagamentos com RNAs multivariadas, foco em sistema preventivo. |

Fonte: Elaborado pela autora.

CAPÍTULO

4

# ANÁLISE EXPLORATÓRIA DOS DADOS

Capítulo a escrever: base de dados integrada, pré-processamento, definição de variáveis, arquitetura e treinamento dos modelos. Junção dos obj 1 e 2 com tabela de metadados de onde veio cada base assim como a especificação de cada uma (com foco).

CAPÍTULO

# 5

# RESULTADOS

Capítulo a escrever: resultados, validação e comparação entre modelos.

CAPÍTULO

6

# CONCLUSÃO

Este projeto busca oferecer uma solução tecnológica robusta, baseada em inteligência artificial, para a antecipação de enchentes em comunidades costeiras catarinenses. Ao integrar variáveis ambientais, hidrológicas e socioeconômicas, espera-se contribuir com conhecimento científico relevante e apoio técnico à tomada de decisões em políticas públicas de gestão de risco. A abordagem proposta é inovadora no contexto regional e se alinha aos desafios contemporâneos impostos pelas mudanças climáticas.

# REFERÊNCIAS

ARIA, M.; CUCCURULLO, C. bibliometrix: An R-tool for comprehensive science mapping analysis. **Journal of Informetrics**, v. 11, n. 4, p. 959–975, 2017. Disponível em: <https://doi.org/10.1016/j.joi.2017.08.007>. Acesso em: 28 out. 2026. Citado nas páginas 20 e 21.

ARORA, A. *et al.* Optimization of state-of-the-art fuzzy-metaheuristic ANFIS-based machine learning models for flood susceptibility prediction mapping in the Middle Ganga Plain, India. **Science of the Total Environment**, v. 750, 2021. Art. 141565. Disponível em: <https://doi.org/10.1016/j.scitotenv.2020.141565>. Acesso em: 28 out. 2026. Citado na página 26.

BRASIL. **Atlas Irrigação: Uso da Água na Agricultura Irrigada**. Brasília: Agência Nacional de Águas e Saneamento Básico (ANA), 2021. Citado na página 10.

COSTACHE, R. *et al.* Flash-flood susceptibility assessment using multi-criteria decision making and machine learning supported by remote sensing and GIS techniques. **Remote Sensing**, v. 12, n. 1, 2020. Art. 106. Disponível em: <https://doi.org/10.3390/rs12010106>. Acesso em: 28 out. 2026. Citado na página 26.

DIAS, M. R. F. *et al.* State of the art techniques for flood prediction models – a systematic review. In: **17th Seminar on Power Electronics and Control (SEPOC)**. [s.n.], 2025. p. 1–7. Disponível em: <https://doi.org/10.1109/SEPOC67005.2025.11297645>. Acesso em: 28 out. 2026. Citado na página 20.

DODANGEH, E. *et al.* Integrated machine learning methods with resampling algorithms for flood susceptibility prediction. **Science of the Total Environment**, v. 705, 2020. Art. 135983. Disponível em: <https://doi.org/10.1016/j.scitotenv.2019.135983>. Acesso em: 28 out. 2026. Citado na página 26.

ESTRADA, A. V. **Aplicação de redes neurais artificiais em modelos de previsão de demanda de água**. 2021. UDESC. Citado nas páginas 30 e 31.

FANG, Z. *et al.* Predicting flood susceptibility using LSTM neural networks. **Journal of Hydrology**, v. 594, 2021. Art. 125734. Disponível em: <https://doi.org/10.1016/j.jhydrol.2020.125734>. Acesso em: 28 out. 2026. Citado na página 26.

HU, C. *et al.* Deep learning with a Long Short-Term Memory networks approach for rainfall–runoff simulation. **Water**, v. 10, n. 11, 2018. Art. 1543. Disponível em: <https://doi.org/10.3390/w10111543>. Acesso em: 28 out. 2026. Citado na página 26.

IPCC. **Climate Change 2021: The Physical Science Basis. Contribution of Working Group I to the Sixth Assessment Report of the Intergovernmental Panel on Climate Change**. Cambridge, UK; New York, NY, USA: Cambridge University Press, 2021. Citado na página 10.

IPCC. **Climate Change 2022: Impacts, Adaptation and Vulnerability**. Cambridge, UK: Cambridge University Press, 2022. Citado na página 20.

ISLAM, T. *et al.* A systematic review of urban flood susceptibility mapping: Remote sensing, machine learning, and other modeling approaches. **Remote Sensing**, v. 17, n. 3, 2025. Art. 524. Disponível em: <https://doi.org/10.3390/rs17030524>. Acesso em: 28 out. 2026. Nenhuma citação no texto.

JANIZADEH, S. *et al.* Prediction success of machine learning methods for flash flood susceptibility mapping in the Tafresh Watershed, Iran. **Sustainability**, v. 11, n. 19, 2019. Art. 5426. Disponível em: <https://doi.org/10.3390/su11195426>. Acesso em: 28 out. 2026. Citado na página 26.

KRATZERT, F. *et al.* Rainfall–runoff modelling using Long Short-Term Memory (LSTM) networks. **Hydrology and Earth System Sciences**, v. 22, p. 6005–6022, 2018. Disponível em: <https://doi.org/10.5194/hess-22-6005-2018>. Acesso em: 28 out. 2026. Citado na página 20.

MAGRO, R. B. **Utilização de técnicas de inteligência computacional para estimativa de vazões afluentes**. 2022. UFPel. Citado nas páginas 30 e 31.

MOSAVI, A.; OZTURK, P.; CHAU, K.-W. Flood prediction using machine learning models: Literature review. **Water**, v. 10, n. 11, 2018. Art. 1536. Disponível em: <https://doi.org/10.3390/w10111536>. Acesso em: 28 out. 2026. Citado nas páginas 10, 14, 20, 30 e 31.

NEARING, G. *et al.* Global prediction of extreme floods in ungauged watersheds. **Nature**, v. 627, p. 559–563, 2024. Disponível em: <https://doi.org/10.1038/s41586-024-07145-1>. Acesso em: 28 out. 2026. Citado nas páginas 20 e 27.

NEARING, G. S. *et al.* What role does hydrological science play in the age of machine learning? **Water Resources Research**, v. 57, n. 3, 2021. Art. e2020WR028091. Disponível em: <https://doi.org/10.1029/2020WR028091>. Acesso em: 28 out. 2026. Citado nas páginas 20 e 28.

OLIVEIRA, R. A.; MARTINS, C. S.; MENDIONDO, E. M. Análise do uso de redes neurais artificiais na previsão de vazões em rios urbanos. In: **XX SBRH**. [S.l.: s.n.], 2013. Citado nas páginas 14, 30 e 31.

PAGE, M. J. *et al.* The PRISMA 2020 statement: An updated guideline for reporting systematic reviews. **BMJ**, v. 372, 2021. Art. n71. Disponível em: <https://doi.org/10.1136/bmj.n71>. Acesso em: 28 out. 2026. Citado nas páginas 20 e 21.

RAFIEI-SARDOOI, E. *et al.* Evaluating urban flood risk using hybrid method of TOPSIS and machine learning. **International Journal of Disaster Risk Reduction**, v. 66, 2021. Art. 102614. Disponível em: <https://doi.org/10.1016/j.ijdrr.2021.102614>. Acesso em: 28 out. 2026. Citado na página 26.

ROBERTS, D. R. *et al.* Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. **Ecography**, v. 40, n. 8, p. 913–929, 2017. Disponível em: <https://doi.org/10.1111/ecog.02881>. Acesso em: 28 out. 2026. Citado na página 28.

SAHA, A. *et al.* Flood susceptibility assessment using novel ensemble of Hyperpipes and support vector regression algorithms. **Water**, v. 13, n. 2, 2021. Art. 241. Disponível em: <https://doi.org/10.3390/w13020241>. Acesso em: 28 out. 2026. Citado na página 27.

SHAHABI, H. *et al.* Flood detection and susceptibility mapping using Sentinel-1 remote sensing data and a machine learning approach: Hybrid intelligence of bagging ensemble based on K-nearest neighbor classifier. **Remote Sensing**, v. 12, n. 2, 2020. Art. 266. Disponível em: <https://doi.org/10.3390/rs12020266>. Acesso em: 28 out. 2026. Citado na página 26.

SHEN, C. A transdisciplinary review of deep learning research and its relevance for water resources scientists. **Water Resources Research**, v. 54, n. 11, p. 8558–8593, 2018. Disponível em: <https://doi.org/10.1029/2018WR022643>. Acesso em: 28 out. 2026. Citado na página 20.

SOARES, D. G.; TEIVE, R. C. G. Previsão de cheias do Rio Itajaí-Açu utilizando redes neurais artificiais. In: **SIBGRAPI**. [S.l.: s.n.], 2015. Citado nas páginas 30 e 31.

TYRALIS, H.; PAPACHARALAMPOUS, G.; LANGOUSIS, A. A brief review of Random Forests for water scientists and practitioners and their recent history in water resources. **Water**, v. 11, n. 5, 2019. Art. 910. Disponível em: <https://doi.org/10.3390/w11050910>. Acesso em: 28 out. 2026. Citado na página 26.

VALLE, R. F. **Avaliação da utilização de redes neurais para previsão do risco de inundação em Curitiba/PR**. 2021. UTFPR. Citado nas páginas 30 e 31.

WAHL, T. *et al.* Increasing risk of compound flooding from storm surge and rainfall for major US cities. **Nature Climate Change**, v. 5, p. 1093–1097, 2015. Disponível em: <https://doi.org/10.1038/nclimate2736>. Acesso em: 28 out. 2026. Citado nas páginas 20 e 28.

WU, W. *et al.* Ensemble flood forecasting: Current status and future opportunities. **WIREs Water**, v. 7, n. 3, 2020. Art. e1432. Disponível em: <https://doi.org/10.1002/wat2.1432>. Acesso em: 28 out. 2026. Citado na página 26.

XIANG, Z.; YAN, J.; DEMIR, I. A rainfall–runoff model with LSTM-based sequence-to-sequence learning. **Water Resources Research**, v. 56, n. 1, 2020. Art. e2019WR025326. Disponível em: <https://doi.org/10.1029/2019WR025326>. Acesso em: 28 out. 2026. Citado na página 26.

ZHANG, X. *et al.* Urban drought challenge to 2030 sustainable development goals. **Science of the Total Environment**, Elsevier, v. 693, p. 133455, 2019. Disponível em: <https://doi.org/10.1016/j.scitotenv.2019.07.273>. Acesso em: 28 out. 2026. Citado na página 10.

ZHAO, G. *et al.* Assessment of urban flood susceptibility using semi-supervised machine learning model. **Science of the Total Environment**, v. 659, p. 940–949, 2019. Disponível em: <https://doi.org/10.1016/j.scitotenv.2018.12.217>. Acesso em: 28 out. 2026. Citado na página 26.

Programa de Pós-Graduação em Computação – PPGC
Mestrado em Computação Aplicada - MCA

